

HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN 1
HỌC PHẦN PHÁT TRIỂN CÁC HỆ THỐNG THÔNG MINH



ASSIGNMENT 01

**ĐỀ TÀI: XÂY DỰNG HỆ THỐNG CHẨN ĐOÁN TIÊU ĐƯỜNG
& ĐỊNH GIÁ BẤT ĐỘNG SẢN TÍCH HỢP ĐỒ THỊ TRI THỨC**

Lớp:	D23CTPM01
Họ và tên:	Nguyễn Duy Nghĩa
Mã sinh viên:	B23DCCN600
Giảng viên hướng dẫn:	PGS.TS Trần Đình Quế
Học kỳ:	Học kỳ 1 năm học 2026 – 2027

Hà Nội, 2026

Mục lục

Mục lục	i
1 Cơ sở lý thuyết và Nguyên lý Hệ thống Thông minh	1
1.1 Mã nguồn dự án và sản phẩm bàn giao	1
1.2 Nguồn dữ liệu	1
1.3 Hệ thống thông minh: định nghĩa và dòng chảy thông tin	2
1.3.1 Định nghĩa	2
1.3.2 Dòng chảy thông tin sáu tầng	2
1.4 Biểu diễn dữ liệu — bản chất và vai trò	3
1.4.1 Không gian véc-tơ đặc trưng	3
1.4.2 Ba tầng chuyển hoá biểu diễn	3
1.5 Hai lớp bài toán học có giám sát	4
1.5.1 Phân lớp nhị phân và hàm sigmoid	4
1.5.2 Hồi quy và hàm mất mát bình phương sai số	4
1.5.3 Hàm mất mát có điều chuẩn	4
1.6 Nguyên lý mô hình cơ sở	5
1.7 Sáu họ thuật toán học máy sử dụng	5
1.8 Hệ thống độ đo đánh giá	5
1.8.1 Ma trận nhầm lẫn và bốn độ đo phân lớp	5
1.8.2 Ba độ đo hồi quy	6
1.9 Đồ thị Tri thức	7
1.9.1 Giới hạn cố hữu của mô hình hộp đen	7
1.9.2 Định nghĩa hình thức	7
1.9.3 Kiến trúc năm tầng	7
1.9.4 Ba vai trò của đồ thị trong hệ thống	9
1.9.5 Ranh giới trung thực về nguồn số liệu	10
1.9.6 Phép tính tài chính	10
1.10 Giao thức thực nghiệm chung	10
1.10.1 Chia dữ liệu ba phần	10
1.10.2 Bốn thực nghiệm có kiểm soát	11
1.10.3 Tính tái lập	11
2 Hệ thống Chẩn đoán Nguy cơ Tiểu đường	12
2.1 Phát biểu bài toán	12
2.1.1 Hiện tượng thực tế và người dùng	12
2.1.2 Phát biểu hình thức	12
2.2 Tập dữ liệu và nguồn gốc	12
2.3 Làm sạch dữ liệu: khi số 0 không phải là số đo	13
2.4 Phân tích khám phá dữ liệu	14
2.4.1 Phân phối biến mục tiêu	15
2.4.2 Phân phối đặc trưng quan trọng nhất	15
2.4.3 So sánh phân phối giữa hai nhóm	16
2.4.4 Giá trị ngoại lai	17
2.5 Thiết kế đặc trưng	17

2.6	Ma trận tương quan và sàng lọc đặc trưng	18
2.7	Chia dữ liệu và mô hình cơ sở	19
2.8	Thực nghiệm 1 — Đối đầu năm mô hình	19
2.8.1	Đường cong ROC — khả năng xếp hạng độc lập với ngưỡng	21
2.8.2	Lưới ma trận nhầm lẫn — sai theo kiểu gì	22
2.9	Thực nghiệm 2 — Siêu tham số và ngưỡng quyết định	22
2.9.1	Khảo sát số láng giềng k	23
2.9.2	Quét ngưỡng quyết định	24
2.10	Thực nghiệm 3 — Ảnh hưởng của cách biểu diễn dữ liệu	26
2.10.1	So sánh biên độ: biểu diễn hay thuật toán?	27
2.11	Thực nghiệm 4 — Kiểm chuẩn ngoài phân phối	27
2.12	Mức độ quan trọng của đặc trưng	28
2.13	Tích hợp Đồ thị Tri thức Y sinh	29
2.13.1	Từ xác suất tới tầng nguy cơ	29
2.13.2	Đồ thị của một ca cụ thể	29
2.13.3	Chuỗi suy luận đầy đủ	30
2.13.4	Gói chăm sóc sức khỏe và giải pháp dược phẩm	30
2.14	Ứng dụng web	32
3	Hệ thống Định giá Bất động sản Việt Nam	36
3.1	Phát biểu bài toán	36
3.1.1	Hiện tượng thực tế và người dùng	36
3.1.2	Phát biểu hình thức	36
3.2	Tập dữ liệu và quy trình làm sạch	36
3.2.1	Nguồn dữ liệu	36
3.2.2	Tỷ lệ dữ liệu khuyết	37
3.2.3	Tách địa chỉ thành hai cấp hành chính	37
3.3	Phân tích khám phá dữ liệu	37
3.3.1	Ba biến người mua thật sự cân nhắc	38
3.3.2	Phân phối biến mục tiêu	39
3.3.3	Quan hệ giữa diện tích và giá	40
3.3.4	Vị trí hành chính và tình trạng pháp lý	40
3.3.5	Ma trận tương quan	42
3.4	Thiết kế đặc trưng và biểu diễn	43
3.5	Thực nghiệm 1 — Đối đầu năm mô hình	43
3.5.1	Giá dự đoán so với giá thật	45
3.5.2	Phân tích phần dư	46
3.6	Thực nghiệm 2 — Khảo sát độ sâu của rừng ngẫu nhiên	47
3.7	Thực nghiệm 3 — Ảnh hưởng của cách biểu diễn dữ liệu	48
3.8	Thực nghiệm 4 — Kiểm chuẩn ngoài phân phối	49
3.9	Mức độ quan trọng của đặc trưng	50
3.10	Tích hợp Đồ thị Tri thức Đô thị – Tài chính	51
3.10.1	Phân khúc thị trường	51
3.10.2	Đồ thị của một ca cụ thể	52
3.10.3	Gói tài chính mua nhà	52
3.10.4	Tiện ích hạ tầng đô thị	53
3.11	Ứng dụng web	54

4	Kết luận và Hướng phát triển	58
4.1	Tổng kết kết quả	58
4.2	Phân tích khoa học — bảy phát hiện	58
4.2.1	Phát hiện 1 — Kết quả vượt trần tài liệu là dấu hiệu của lỗi	58
4.2.2	Phát hiện 2 — Quét ngưỡng đòi hỏi mô hình cho xác suất liên tục	58
4.2.3	Phát hiện 3 — Cực trị chạm biên dài khảo sát thì chưa phải cực trị	59
4.2.4	Phát hiện 4 — “Biểu diễn quan trọng hơn thuật toán” là SAI nếu phát biểu trần	59
4.2.5	Phát hiện 5 — “Đặc trưng tốt” là thuộc tính của cặp đặc trưng – thuật toán	60
4.2.6	Phát hiện 6 — Giả định về phân phối phải được đo trước khi viện dẫn	60
4.2.7	Phát hiện 7 — Sai số gộp che mất hai chế độ sai khác hẳn nhau	60
4.3	Phản chiếu về vai trò của biểu diễn dữ liệu	60
4.3.1	Tầng 1 — Biểu diễn quyết định thuật toán nhìn thấy gì	60
4.3.2	Tầng 2 — Biểu diễn có thể mã hoá lẫn cả câu trả lời	61
4.3.3	Tầng 3 — Giới hạn của việc thiết kế biểu diễn	61
4.4	Vai trò của Đồ thị Tri thức — điều mô hình không làm được	61
4.5	Hạn chế của hệ thống	62
4.5.1	Hạn chế về dữ liệu	62
4.5.2	Hạn chế về mô hình	62
4.5.3	Hạn chế về tri thức miền trong đồ thị	62
4.6	Hướng phát triển	63
	Tài liệu tham khảo	64

Chương 1

Cơ sở lý thuyết và Nguyên lý Hệ thống Thông minh

1.1 Mã nguồn dự án và sản phẩm bàn giao

Toàn bộ sản phẩm của báo cáo này là mã nguồn mở và chạy lại được từ đầu:

- **Kho mã nguồn:**
<https://github.com/Nghaiz/Assignment-01-Intelligent-System>
- **Ứng dụng web đã triển khai công khai:**
<https://html-nguyen-duy-nghia-assignment-01-intelligent-system.streamlit.app>
- **Đồ thị Tri thức:** nạp thật lên máy chủ Neo4j Aura (Kernel 5.27-aura, bản enterprise), có bản offline dự phòng.

Cấu trúc kho mã và vai trò từng thành phần được tóm tắt ở Bảng 1.1.

Bảng 1.1. Cấu trúc kho mã nguồn và vai trò từng thành phần

Đường dẫn	Nội dung
src/config.py	Đường dẫn, hằng số, hạt giống ngẫu nhiên, kiểu vẽ biểu đồ (nguồn duy nhất — SSOT)
src/preprocess.py	Làm sạch dữ liệu và xây dựng biểu diễn đặc trưng
src/train.py	Định nghĩa và huấn luyện 5 + 5 mô hình
src/evaluate.py	Bộ độ đo và bốn thực nghiệm có kiểm soát
src/viz.py	Sinh toàn bộ 44 biểu đồ của báo cáo
src/kg/ontology.py	Bản thể học, phân tầng nguy cơ và phân khúc thị trường
src/kg/catalog_pharmacy.py	Danh mục bán lẻ dược phẩm — mã hàng, khoảng giá, gói chăm sóc
src/kg/catalog_urban.py	Hạ tầng tiện ích đô thị và phép tính tài chính vay mua nhà
notebooks/	Hai Jupyter Notebook, đủ 22 mục theo đề bài
app/	Ứng dụng web Streamlit — ba trang, bốn tab mỗi trang công cụ
report/	Mã nguồn $\text{L}^{\text{A}}\text{T}_{\text{E}}\text{X}$ của chính báo cáo này
tests/	355 bài kiểm thử tự động
run_pipeline.py	Một lệnh tái tạo toàn bộ kết quả, khoảng 90 giây

1.2 Nguồn dữ liệu

Hệ thống sử dụng hai tập dữ liệu có cấu trúc thực tế thu thập từ nền tảng Kaggle, cả hai đều đáp ứng đủ các tiêu chí: mang ý nghĩa thực tiễn, có biến mục tiêu rõ ràng và đủ dữ liệu để huấn luyện thuật toán học máy.

- **Tập Pima Indians Diabetes** — dữ liệu chẩn đoán y tế phục vụ bài toán đánh giá nguy cơ tiểu đường (*Link dataset:* <https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database>)
- **Tập Vietnam Housing** — dữ liệu thuộc tính vật lý và vị trí của các bất động sản tại Việt Nam phục vụ bài toán định giá (*Link dataset:* <https://www.kaggle.com/datasets/huutri148/vietnam-housing-dataset>)

Đặc tả chi tiết của từng tập — hiện tượng thực tế, quan sát, đặc trưng, biến mục tiêu, loại bài toán — được trình bày ở Mục 2.2 và Mục 3.2.

1.3 Hệ thống thông minh: định nghĩa và dòng chảy thông tin

1.3.1 Định nghĩa


Một **hệ thống thông minh** (Intelligent System) là hệ thống nhận thông tin từ môi trường, biểu diễn thông tin ấy dưới dạng máy tính xử lý được, học một ánh xạ từ biểu diễn sang kết luận, rồi *tác động ngược trở lại* môi trường bằng một quyết định hoặc một khuyến nghị. Ba mệnh đề trong định nghĩa này đều là điều kiện cần:

1. **Có biểu diễn.** Không có bước chuyển từ hiện tượng sang véc-tơ số thì không có gì để học.
2. **Có học từ dữ liệu.** Nếu ánh xạ được viết tay bằng luật cứng thì đó là hệ chuyên gia, không phải hệ thống học máy.
3. **Có tác động trở lại.** Một mô hình chỉ in ra con số rồi dừng lại chưa phải là hệ thống; nó mới là một thành phần của hệ thống.

Mệnh đề thứ ba là mệnh đề dễ bị bỏ qua nhất, và cũng chính là lý do báo cáo này dành hẳn hai tầng cuối của Đồ thị Tri thức (Mục 1.9) cho phần việc ấy: mô hình trả về xác suất 0,545 hoặc con số 8,42 tỷ đồng, còn đồ thị mới là thứ biến hai con số ấy thành *một giỏ hàng gồm năm mặt hàng với chi phí xác định và một khoản trả góp 47,5 triệu đồng mỗi tháng cùng mức thu nhập tối thiểu cần có*.

1.3.2 Dòng chảy thông tin sáu tầng

Hình 1.1 trình bày kiến trúc chung mà cả hai hệ thống trong báo cáo đều tuân theo. Đây là sản phẩm bàn giao số 4 theo Mục 24 của đề bài (Sơ đồ kiến trúc hệ thống).



Hình 1.1. Dòng chảy thông tin sáu tầng của một hệ thống thông minh, áp dụng đồng thời cho hệ thống chẩn đoán tiểu đường và hệ thống định giá bất động sản

Loại biểu đồ: Sơ đồ khối tuần tự (sequential block diagram). Mỗi khối là một tầng xử lý, mũi tên một chiều thể hiện hướng đi của thông tin; không có vòng lặp ngược vì đây là kiến trúc suy luận một lượt (single-pass inference), không phải vòng học tăng cường.

Nhận xét: Tầng REPRESENTATION được đặt ở vị trí trung tâm chứ không phải tầng LEARNING MODEL. Đó là một phát biểu có chủ đích của đề bài: mọi tầng phía sau chỉ thao tác trên véc-tơ đặc trưng, nên bất kỳ thông tin nào bị

đánh mất ở tầng biểu diễn thì không tầng nào sau đó khôi phục lại được. Mục 4.2.4 là phần kiểm định thực nghiệm cho nhận định này — và kết quả kiểm định không đơn giản như phát biểu.

Ánh xạ cụ thể của sáu tầng sang hai bài toán được trình bày ở Bảng 1.2.

Bảng 1.2. Ánh xạ sáu tầng kiến trúc sang hai bài toán cụ thể

Tầng	Hệ thống 1 — Tiểu đường	Hệ thống 2 — Bất động sản
Môi trường	Bệnh nhân đến khám sàng lọc	Thị trường nhà đất Việt Nam
Dữ liệu vào	768 hồ sơ Pima Indians Diabetes	30.229 tin đăng rao bán
Biểu diễn	$\mathbf{x} \in \mathbb{R}^{12}$ (8 gốc + 4 thiết kế)	$\mathbf{x} \in \mathbb{R}^{84}$ sau mã hoá one-hot
Mô hình học	5 bộ phân lớp + 1 mô hình cơ sở	5 bộ hồi quy + 1 mô hình cơ sở
Dự đoán	Xác suất mắc bệnh $\hat{p} \in [0, 1]$	Giá dự báo $\hat{y}$ (tỷ VNĐ)
Ứng dụng	Phân tầng nguy cơ, gói chăm sóc có chi phí	Phân khúc, hạn mức vay và trả góp

1.4 Biểu diễn dữ liệu — bản chất và vai trò

1.4.1 Không gian véc-tơ đặc trưng

Mọi thuật toán học máy truyền thống đều làm việc trên một không gian số. Cho tập dữ liệu gồm n quan sát, mỗi quan sát được viết thành một véc-tơ d chiều

$$\mathbf{x}_i = [x_{i1}, x_{i2}, \dots, x_{id}]^\top \in \mathbb{R}^d, \quad i = 1, \dots, n, \quad (1.1)$$

và toàn bộ tập dữ liệu thành ma trận đặc trưng $\mathbf{X} \in \mathbb{R}^{n \times d}$ đi kèm véc-tơ nhãn $\mathbf{y}$. Bài toán học có giám sát là bài toán tìm một hàm $f_\theta : \mathbb{R}^d \rightarrow \mathcal{Y}$ sao cho $f_\theta(\mathbf{x})$ xấp xỉ tốt nhãn thật.

Điểm mấu chốt: *hình học của không gian $\mathbb{R}^d$ quyết định thuật toán nhìn thấy gì*. Với K-Nearest Neighbors, khái niệm “gần nhau” là khoảng cách Euclid

$$D(\mathbf{x}_a, \mathbf{x}_b) = \sqrt{\sum_{j=1}^d (x_{aj} - x_{bj})^2}. \quad (1.2)$$

Nếu một cột có thang đo hàng trăm (Insulin, đơn vị $\mu\text{U/mL}$) đứng cạnh một cột có thang đo phần mười (DiabetesPedigreeFunction), thì trong công thức (1.2) cột thứ nhất lấn át hoàn toàn cột thứ hai — không phải vì nó quan trọng hơn về mặt y học, mà chỉ vì đơn vị đo của nó lớn hơn. Đây là lý do bước chuẩn hoá không phải là thủ tục hình thức.

1.4.2 Ba tầng chuyển hoá biểu diễn

Báo cáo phân biệt rõ ba phép biến đổi thường bị gộp chung dưới tên “tiền xử lý”, vì Thực nghiệm 3 ở cả hai chương sau đo tác động của chúng một cách riêng rẽ:

- Làm sạch (cleaning).** Sửa lại những giá trị mã hoá sai — ví dụ giá trị 0 ở cột Glucose không phải nồng độ đường huyết bằng không mà là quy ước cho “không đo được”. Phép này *sửa lại thông tin sai lệch*.
- Thiết kế đặc trưng (feature engineering).** Tạo cột mới từ các cột đã có, ví dụ Glucose $\times$ BMI. Phép này *đổi dạng thông tin đã có* — nó không mang thêm dữ kiện mới nào vào hệ thống.
- Chuẩn hoá (standardisation).** Đưa mọi cột về cùng thang đo:

$$z_{ij} = \frac{x_{ij} - \mu_j}{\sigma_j}, \quad (1.3)$$

với μ_j, σ_j là trung bình và độ lệch chuẩn của cột j **học trên riêng tập huấn luyện**. Phép này cũng chỉ *đổi dạng*.

Sự phân biệt giữa “đổi dạng thông tin” và “thêm hoặc bớt thông tin” chính là chìa khoá giải thích vì sao cùng một thực nghiệm cho hai kết luận trái ngược trên hai bài toán — xem Mục 4.2.4.

Rò rỉ dữ liệu qua bước tiền xử lý

Các tham số μ_j, σ_j ở công thức (1.3), cũng như giá trị trung vị dùng để điền khuyết, **bắt buộc** phải được ước lượng chỉ từ tập huấn luyện rồi áp lại y nguyên cho tập kiểm tra. Tính trên toàn bộ dữ liệu là rò rỉ dữ liệu (data leakage) [1]: tập kiểm tra đã gián tiếp góp phần định nghĩa phép biến đổi mà nó sắp được đánh giá. Trong dự án này, mọi bước tiền xử lý được gói bên trong đối tượng Pipeline của scikit-learn, nên `fit` về mặt cấu trúc không thể nhìn thấy tập kiểm tra. Mục 2.3 trình bày một trường hợp rò rỉ thật đã xảy ra trong dự án và hậu quả đo được của nó.

1.5 Hai lớp bài toán học có giám sát

1.5.1 Phân lớp nhị phân và hàm sigmoid

Bài toán phân lớp nhị phân có $\mathcal{Y} = \{0, 1\}$. Hồi quy Logistic mô hình hoá *xác suất* thuộc lớp dương bằng cách đưa một tổ hợp tuyến tính qua hàm sigmoid (còn gọi là hàm logistic) [2]:

$$\sigma(z) = \frac{1}{1 + e^{-z}}, \quad z \in \mathbb{R}, \quad (1.4)$$

$$\hat{p}(\mathbf{x}) = P(y = 1 | \mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b) = \frac{1}{1 + \exp[-(\mathbf{w}^\top \mathbf{x} + b)]}. \quad (1.5)$$

Hàm σ ép mọi số thực về khoảng $(0, 1)$, đơn điệu tăng, đối xứng qua điểm $(0, 0.5)$, và có đạo hàm $\sigma'(z) = \sigma(z)[1 - \sigma(z)]$ — tính chất khiến việc tối ưu bằng gradient trở nên gọn gàng.

Hàm mất mát tương ứng là entropy chéo nhị phân (binary cross-entropy, còn gọi là log-loss):

$$\mathcal{L}_{\log}(\boldsymbol{\theta}) = -\frac{1}{n} \sum_{i=1}^n \left[y_i \log \hat{p}_i + (1 - y_i) \log (1 - \hat{p}_i) \right]. \quad (1.6)$$

1.5.2 Hồi quy và hàm mất mát bình phương sai số

Bài toán hồi quy có $\mathcal{Y} = \mathbb{R}$. Hàm mất mát chuẩn là sai số bình phương trung bình:

$$\mathcal{L}_{\text{MSE}}(\boldsymbol{\theta}) = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2, \quad \hat{y}_i = f_{\boldsymbol{\theta}}(\mathbf{x}_i). \quad (1.7)$$

1.5.3 Hàm mất mát có điều chuẩn

Cực tiểu hoá trần các hàm (1.6) hoặc (1.7) dễ dẫn tới học thuộc (overfitting): mô hình khớp cả nhiễu của tập huấn luyện. Điều chuẩn (regularisation) thêm một số hạng phạt vào độ lớn tham số [3]:

$$\mathcal{J}(\boldsymbol{\theta}) = \underbrace{\frac{1}{n} \sum_{i=1}^n \ell(y_i, f_{\boldsymbol{\theta}}(\mathbf{x}_i))}_{\text{sai số trên dữ liệu}} + \underbrace{\frac{\lambda}{2} \|\boldsymbol{\theta}\|_2^2}_{\text{số hạng điều chuẩn } L_2}, \quad \|\boldsymbol{\theta}\|_2^2 = \sum_{j=1}^d \theta_j^2. \quad (1.8)$$

Tham số $\lambda > 0$ điều tiết đánh đổi giữa khớp dữ liệu và giữ mô hình đơn giản. Trong scikit-learn [4], `LogisticRegression` mặc định dùng phạt L_2 với $C = 1/\lambda = 1$ — chi tiết này sẽ trực tiếp giải thích một kết quả phản trực giác ở Mục 2.10, nơi một đặc trưng thiết kế *tốt* lại làm Hồi quy Logistic *kém* đi.

1.6 Nguyên lý mô hình cơ sở

Một con số độ đo đứng một mình không mang thông tin. Accuracy 0,79 là tốt hay tồi phụ thuộc hoàn toàn vào việc đoán mù đạt bao nhiêu. **Mô hình cơ sở** (baseline) là quy tắc đơn giản nhất có thể, không học gì từ đặc trưng, đóng vai trò mốc so sánh bắt buộc (yêu cầu R6 của đề bài):

- **Phân lớp** — luôn đoán lớp chiếm đa số (`DummyClassifier(strategy="most_frequent")`).
- **Hồi quy** — luôn đoán trung vị của tập huấn luyện (`DummyRegressor(strategy="median")`).

Ở bài toán tiểu đường, mô hình cơ sở đạt Accuracy 0,6547 — một con số thoát nhìn không tệ — nhưng Recall bằng 0, tức *bỏ sót toàn bộ người bệnh*. Đây là minh họa trực tiếp cho nghịch lý Accuracy trên dữ liệu lệch lớp, và là lý do mọi kết luận trong Chương 2 đều căn theo F_1 và Recall chứ không căn theo Accuracy.

1.7 Sáu họ thuật toán học máy sử dụng

Năm mô hình cho mỗi bài toán được chọn theo tiêu chí *khác nhau về nguyên lý học*, để phép so sánh nói lên điều gì đó về bản chất dữ liệu chứ không chỉ so sánh các biến thể của cùng một ý tưởng.

Bảng 1.3. Nguyên lý học, giả định và siêu tham số của các thuật toán sử dụng

Thuật toán	Nguyên lý học và giả định	Siêu tham số dùng
Linear Regression	Khớp siêu phẳng cực tiểu hoá (1.7). Giả định quan hệ tuyến tính giữa đặc trưng và mục tiêu; trần hiệu năng bị chặn bởi độ mạnh tương quan tuyến tính.	Mặc định
Logistic Regression	Ranh giới tuyến tính trong không gian log-odds qua (1.5), phạt L_2 theo (1.8). Nhạy với đa cộng tuyến.	<code>max_iter=1000</code>
K-Nearest Neighbors	Không học tham số [5]; nhãn quyết định bởi k láng giềng gần nhất theo (1.2). Bắt buộc chuẩn hoá.	<code>n_neighbors=11</code>
Decision Tree	Chia đệ quy không gian đặc trưng bằng ngưỡng trên từng trục, cực tiểu hoá độ vẩn (Gini hoặc MSE). Bất biến với phép chuẩn hoá đơn điệu.	<code>max_depth=6</code> (phân lớp), 12 (hồi quy)
Random Forest	Tổng hợp nhiều cây trên mẫu bootstrap [6] cộng với chọn ngẫu nhiên tập con đặc trưng; giảm phương sai bằng trung bình hoá.	<code>n_estimators=300/200</code> , <code>max_depth=10/18</code> , <code>min_samples_leaf=5</code>
Support Vector Regression	Tìm ống ϵ mỏng nhất chứa phần lớn điểm [7]; độ phức tạp bậc hai theo số mẫu.	<code>C=10.0</code> , <code>epsilon=0.2</code>
XGBoost	Cộng dồn tuần tự các cây yếu [8], mỗi cây sửa phần dư của tổ hợp trước đó; có điều chuẩn nội tại.	<code>n_estimators=300/500</code> , <code>max_depth=4/6</code> , <code>learning_rate=0.05</code>

1.8 Hệ thống độ đo đánh giá

1.8.1 Ma trận nhầm lẫn và bốn độ đo phân lớp

Với bài toán nhị phân, đối chiếu nhãn thật và nhãn dự đoán cho bốn ô của **ma trận nhầm lẫn** (Bảng 1.4).

Bảng 1.4. Ma trận nhầm lẫn — ý nghĩa lâm sàng của từng ô

Ký hiệu	Tên	Ý nghĩa trong bài toán chẩn đoán
TP	Dương tính thật	Người bệnh, được phát hiện đúng
TN	Âm tính thật	Người khoẻ, được kết luận đúng
FP	Dương tính giả	Người khoẻ bị báo động nhầm — tốn thêm một lần xét nghiệm
FN	Âm tính giả	Người bệnh bị bỏ sót — sai lầm nghiêm trọng nhất

Bốn độ đo chuẩn được định nghĩa từ bốn ô này:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}, \quad (1.9)$$

$$\text{Precision} = \frac{TP}{TP + FP}, \quad (1.10)$$

$$\text{Recall} = \frac{TP}{TP + FN}, \quad (1.11)$$

$$F_1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}. \quad (1.12)$$

Cách đọc bốn công thức trên trong ngữ cảnh y tế:

- **Accuracy (1.9)** — tỷ lệ đúng chung. Mất ý nghĩa khi hai lớp lệch nhau: ở tập Pima, đoán “tất cả đều khoẻ” đã đạt 65,5%.
- **Precision (1.10)** — trong những ca bị báo động, bao nhiêu phần trăm là báo động thật. Precision thấp nghĩa là hệ thống gây phiền nhiễu.
- **Recall (1.11)** — trong toàn bộ người bệnh, bao nhiêu phần trăm được tìm ra. **Đây là độ đo quan trọng nhất của bài toán sàng lọc**, vì FN là sai lầm đắt nhất.
- F_1 (1.12) — trung bình điều hoà của hai độ đo trên. Trung bình điều hoà (chứ không phải trung bình cộng) phạt nặng trường hợp một trong hai độ đo gần 0: mô hình cơ sở có Precision = Recall = 0 nên $F_1 = 0$, phản ánh đúng thực chất.

Ngoài bốn độ đo trên, báo cáo dùng **ROC-AUC** — diện tích dưới đường cong biểu diễn Recall theo tỷ lệ Dương tính giả khi ngưỡng quyết định quét từ 1 về 0. ROC-AUC [9] đo *khả năng xếp hạng* của mô hình và độc lập với ngưỡng, nên nó là độ đo duy nhất trong nhóm không thay đổi khi ta chỉnh ngưỡng ở Thử nghiệm 1.

1.8.2 Ba độ đo hồi quy

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|, \quad (1.13)$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (1.14)$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}. \quad (1.15)$$

MAE (1.13) giữ nguyên đơn vị của biến mục tiêu, nên “MAE = 1,05” đọc thẳng được là “sai trung bình 1,05 tỷ đồng mỗi căn”. RMSE (1.14) bình phương sai số trước khi lấy trung bình nên phạt nặng các ca sai lớn; khoảng cách

giữa RMSE và MAE do đó là một chỉ báo về mức độ tồn tại của các sai cực đoan. R^2 (1.15) là tỷ lệ phương sai của biến mục tiêu được mô hình giải thích: $R^2 = 1$ là dự báo hoàn hảo, $R^2 = 0$ là ngang với việc luôn đoán giá trị trung bình, và $R^2 < 0$ nghĩa là mô hình còn tệ hơn cả đoán trung bình.

R^2 không so sánh được giữa hai tập dữ liệu khác nhau

Mẫu số của (1.15) là phương sai của chính biến mục tiêu. Nếu một tập dữ liệu có mục tiêu bị thu hẹp dải giá trị — đúng trường hợp của tập bất động sản, xem Mục 3.3.2 — thì mẫu số nhỏ đi và cùng một sai số tuyệt đối sẽ cho R^2 thấp hơn. Do đó $R^2 = 0,61$ ở đây khắt khe hơn con số 0,61 trên một tập có dải giá trải rộng.

1.9 Đồ thị Tri thức

1.9.1 Giới hạn cố hữu của mô hình hộp đen

Một mô hình học máy được huấn luyện tốt trả lời được câu hỏi “bao nhiêu” và “khả năng nào”, nhưng không trả lời được “vì vậy thì phải làm gì”. Xác suất 0,545 không tự nó nói cho bác sĩ biết cần chỉ định xét nghiệm nào, cũng không nói cho người bệnh biết phải mua máy đo nào và tốn bao nhiêu; con số 8,42 tỷ không tự nó nói cho người mua biết ngân hàng cho vay tối đa bao nhiêu và mỗi tháng phải trả bao nhiêu. Khoảng trống giữa *con số dự báo* và *hành động cụ thể* là khoảng trống mà tri thức miền phải lấp, và Đồ thị Tri thức là cấu trúc dữ liệu để mã hoá tri thức ấy dưới dạng máy suy luận được.

1.9.2 Định nghĩa hình thức

Một **Đồ thị Tri thức** [10, 11] là bộ ba

$$\mathcal{KG} = (V, E, R), \quad (1.16)$$

trong đó V là tập *thực thể* (đỉnh), R là tập *loại quan hệ*, và $E \subseteq V \times R \times V$ là tập *cạnh có nhãn*. Mỗi phần tử của E là một **bộ ba tri thức** (knowledge triplet)

$$(h, r, t) \in E, \quad h, t \in V, r \in R, \quad (1.17)$$

đọc là “chủ thể h có quan hệ r với đối tượng t ”. Ví dụ thật lấy từ đồ thị của hệ thống thứ nhất:


(Bệnh nhân #192, HAS_BIOMARKER, Glucose = 159 mg/dL)
 (Mô hình K-Nearest Neighbors, PRODUCES, Xác suất rủi ro 54.5%)
 (Xác suất rủi ro 54.5%, MAPS_TO_DISEASE, ICD-10 E11)
 (Nhóm Nguy cơ Cao, RECOMMENDS_PACKAGE, Gói Theo dõi Chuyên sâu)
 (Gói Theo dõi Chuyên sâu, FULFILLED_BY, Nhà thuốc FPT Long Châu)

Năm bộ ba trên nối liền một mạch từ số đo sinh học tới nơi mua được hàng — năng lực mà mô hình đơn lẻ không có. Đồ thị của dự án này có $|V| = 117$, $|E| = 133$ và $|R| = 28$ trên 6 ca mẫu, đã nạp thật lên máy chủ Neo4j Aura.

1.9.3 Kiến trúc năm tầng


Bộ ba (V, E, R) ở (1.16) mô tả *cấu trúc*, nhưng không nói gì về *tổ chức*. Đồ thị của dự án này được tổ chức thành năm tầng ở cả hai miền — Hình 1.2 và Hình 1.3. Mỗi tầng là một nhóm loại thực thể, và thông tin chỉ chảy theo một chiều từ tầng trên xuống tầng dưới.

Kiến trúc Đồ thị Tri thức Y sinh — 5 tầng Từ chỉ số sinh tồn tới gói chăm sóc mua được tại nhà thuốc



Hình 1.2. Kiến trúc năm tầng của Đồ thị Tri thức Y sinh — từ chỉ số sinh tồn tới gói chăm sóc mua được tại nhà thuốc

Kiến trúc Đồ thị Tri thức Đô thị - Tài chính — 5 tầng Từ thuộc tính căn nhà tới hạn mức vay và tiện ích hạ tầng quanh đó



Hình 1.3. Kiến trúc năm tầng của Đồ thị Tri thức Đô thị – Tài chính — từ thuộc tính căn nhà tới hạn mức vay và tiện ích hạ tầng quanh đó

Loại biểu đồ: Sơ đồ tầng (layered schema diagram). Khác với ảnh chụp đồ thị của một ca cụ thể ở Hình 2.16 và Hình 3.14 — vốn cho thấy *dữ liệu* — hai hình trên cho thấy *lược đồ*: đồ thị có mấy tầng, mỗi tầng chứa loại thực thể nào, thông tin chảy theo hướng nào.

Nhận xét: Hai kiến trúc song song nhau đến từng tầng, và đó là thiết kế có chủ đích. Tầng 1–2 là *quan sát*, tầng 3 là *suy luận của mô hình*, tầng 4 là *gói giải pháp có chi phí*, tầng 5 là *hạ tầng cung ứng*. Nhờ cùng khung, một câu hỏi đặt ra ở miền này luôn có câu hỏi đối ứng ở miền kia: “gói chăm sóc tốn bao nhiêu mỗi tháng” đối ứng với “khoản vay trả góp bao nhiêu mỗi tháng”.

Hai hình trên được vẽ tự động từ chính khai báo KG_LAYERS trong `src/kg/ontology.py`, nên chúng không thể mô tả một kiến trúc mà mã nguồn không còn dùng. Một bài kiểm thử canh đúng điều đó: mọi loại thực thể mà mã nguồn thật sự sinh ra đều phải thuộc đúng một tầng.

1.9.4 Ba vai trò của đồ thị trong hệ thống

- Diễn giải (interpretability).** Đường đi từ đỉnh “Bệnh nhân” tới đỉnh “Gói chăm sóc” là một chuỗi bước đọc được bằng ngôn ngữ tự nhiên, khác hẳn trọng số của một cây tăng cường.
- Nối tri thức miền.** Bảng phân loại ICD-10 [12], ngưỡng BMI của WHO [13], danh mục hàng của nhà thuốc, tỷ lệ LTV và ngưỡng DTI của ngân hàng — những tri thức này không có trong dữ liệu huấn luyện và cũng không nên học từ dữ liệu; chúng được khai báo tường minh thành đỉnh và cạnh.

3. **Sinh hành động có chi phí.** Truy vấn đồ thị theo tầng nguy cơ hoặc phân khúc giá trả về ngay một gói kèm con số: chi phí ban đầu, chi phí duy trì hằng tháng, hoặc khoản trả góp và mức thu nhập tối thiểu. Đây chính là đầu ra của tầng APPLICATION ở Hình 1.1.

1.9.5 Ranh giới trung thực về nguồn số liệu

Hai tầng cuối của mỗi đồ thị chứa số liệu *không* đến từ tập dữ liệu huấn luyện, nên nguồn gốc của chúng phải được nói rõ chứ không được trình bày lẫn với kết quả đo được:

- **Tên mặt hàng là tên thật** đang được bán tại hệ thống nhà thuốc. **Giá là khoảng tham khảo có ghi ngày chốt** (26/08/2026), biên soạn tay từ danh mục công khai — không phải bản ghi giá trực tiếp. Mỗi mặt hàng mang theo một đường dẫn tra cứu để người dùng đối chiếu giá hiện hành.
- **Cụm tiện ích đô thị được mô hình hoá theo phân khúc**, không phải kết quả khảo sát thực địa từng quận: tập dữ liệu gốc chỉ có địa chỉ hành chính, không có tọa độ.
- **Điều kiện vay là minh hoạ** theo mặt bằng lãi suất công bố, không phải chào giá của một ngân hàng cụ thể. Ngược lại, *phép tính* trả góp là toán học thuần túy và kiểm chứng được — xem Mục 1.9.6.

Phương án thu thập giá trực tiếp từ website bán lẻ đã được cân nhắc và bị loại, vì nó phá vỡ yêu cầu R14 về tính tái lập: giá đổi theo ngày nên hai lần chạy cách nhau một tuần sẽ cho hai bộ số khác nhau, trong khi cả báo cáo được xây trên cam kết “chạy lại cho kết quả trùng khít”.

1.9.6 Phép tính tài chính

Khoản trả góp cố định hằng tháng của một khoản vay niên kim là

$$M = P \cdot \frac{r}{1 - (1 + r)^{-n}}, \quad r = \frac{r_{\text{năm}}}{12}, \quad n = 12T, \quad (1.18)$$

với P là dư nợ gốc, $r_{\text{năm}}$ là lãi suất danh nghĩa theo năm và T là kỳ hạn tính bằng năm. Tổng tiền lãi phải trả trong toàn bộ kỳ hạn là $Mn - P$. Mức thu nhập tối thiểu suy ra từ ngưỡng tỷ lệ nợ trên thu nhập (Debt-To-Income):

$$I_{\min} = \frac{M}{DTI_{\max}}. \quad (1.19)$$

Ba công thức này được kiểm thử tự động bằng một phép tính độc lập viết lại tay, chứ không đối chiếu với chính hàm cần kiểm.

1.10 Giao thức thực nghiệm chung

Hai chương sau dùng chung một giao thức, để mọi so sánh giữa hai bài toán là so sánh công bằng.

1.10.1 Chia dữ liệu ba phần

Dữ liệu được cắt làm ba, theo đúng thứ tự sau:

1. **Tập ngoại kiểm (OOD)**, 10% — cắt ra *trước tiên* và không tham gia bất kỳ bước nào của quá trình phát triển, kể cả tinh chỉnh siêu tham số.
2. **Tập kiểm tra**, 20% **phần còn lại** — dùng để so sánh mô hình.
3. **Tập huấn luyện, phần còn lại** — dùng để học tham số.

Lý do tách riêng tập ngoại kiểm: sau nhiều vòng thử nghiệm, tập kiểm tra thông thường đã *gián tiếp* ảnh hưởng tới lựa chọn mô hình, nên nó không còn là ước lượng không chệch của hiệu năng thực tế. Tập ngoại kiểm đóng vai trò “dữ liệu thế giới thực” chưa từng bị nhìn thấy.

1.10.2 Bốn thực nghiệm có kiểm soát

Mỗi bài toán chạy bốn thực nghiệm cùng khuôn (đề bài yêu cầu tối thiểu ba — R8), mỗi thực nghiệm chỉ đổi *một* biến và giữ nguyên mọi thứ còn lại:

Bảng 1.5. Bốn thực nghiệm có kiểm soát, áp dụng song song cho hai bài toán

TN	Biến được thay đổi	Câu hỏi trả lời	Kết quả ở
1	Đổi đầu 5 thuật toán	Nguyên lý học nào hợp với dữ liệu này?	2.8, 3.5
2	Siêu tham số cốt lõi	Cực trị nằm ở đâu, có chạm biên dài khảo sát không?	2.9, 3.6
3	Cách biểu diễn dữ liệu	Biểu diễn hay thuật toán chi phối kết quả?	2.10, 3.7
4	Tập đánh giá (kiểm tra → ngoại kiểm)	Mô hình tổng quát hoá được tới đâu?	2.11, 3.8

1.10.3 Tính tái lập

Hạt giống ngẫu nhiên cố định tại `RANDOM_STATE = 42` khai báo một lần duy nhất trong `src/config.py` và được mọi thành phần dùng lại. Một lệnh `python run_pipeline.py` sinh lại toàn bộ mô hình, biểu đồ, bảng số và đồ thị tri thức trong khoảng 90 giây.

Một lưu ý trung thực về mức độ tái lập: các tệp `models/*.joblib` chạy lại cho kết quả trùng khít, nhưng vài tệp CSV của bài toán bất động sản có thể lệch ở chữ số cuối của số thực (bậc 10^{-16}) — ví dụ MAE của Random Forest đổi từ 1,0818214861905244 thành 1,0818214861905247. Nguyên nhân là phép cộng dồn song song trong rừng ngẫu nhiên không có tính kết hợp. Ở độ chính xác báo cáo — bốn chữ số thập phân — mọi con số đều trùng khớp.

Chương 2

Hệ thống Chẩn đoán Nguy cơ Tiểu đường

2.1 Phát biểu bài toán

2.1.1 Hiện tượng thực tế và người dùng

Đái tháo đường type 2 tiến triển âm thầm: người bệnh thường không có triệu chứng rõ rệt cho tới khi biến chứng đã hình thành. Vì vậy giá trị của một hệ thống trong miền này không nằm ở chỗ “chẩn đoán chính xác” — việc ấy thuộc về xét nghiệm HbA1c tĩnh mạch — mà nằm ở chỗ **sàng lọc**: từ những chỉ số đo được rẻ và nhanh, chỉ ra ai cần đi làm xét nghiệm khẳng định.

Việc xác định đúng vai trò này quyết định mọi lựa chọn kỹ thuật về sau. Nó là lý do báo cáo chấm điểm bằng F_1 và Recall chứ không bằng Accuracy (Mục 1.6), và là lý do Thực nghiệm 2 hạ ngưỡng quyết định xuống tận 0,15 (Mục 2.9).

2.1.2 Phát biểu hình thức

Cho một hồ sơ y sinh $\mathbf{x} \in \mathbb{R}^d$ gồm các chỉ số đo được của một người, hãy học hàm

$$f_{\theta} : \mathbb{R}^d \longrightarrow [0, 1], \quad \hat{p} = f_{\theta}(\mathbf{x}) = P(\text{Outcome} = 1 \mid \mathbf{x}), \quad (2.1)$$

rồi quy xác suất về nhãn nhị phân qua một ngưỡng quyết định θ :

$$\hat{y} = \mathbb{K}[\hat{p} \geq \theta], \quad \theta \in (0, 1). \quad (2.2)$$

Ngưỡng θ ở (2.2) là một tham số của **hệ thống**, không phải của mô hình: nó không được học từ dữ liệu mà được chọn theo mục tiêu sử dụng. Việc tách bạch hai thứ này là điều kiện cần để Thực nghiệm 2 có nghĩa.

Bảng 2.1. Đặc tả bài toán chẩn đoán nguy cơ tiểu đường

Hạng mục	Nội dung
Hiện tượng thực tế	Tình trạng chuyển hoá glucose và nguy cơ mắc đái tháo đường type 2
Một quan sát	Một hồ sơ y sinh của một người trưởng thành
Loại bài toán	Phân lớp nhị phân (Binary Classification)
Biến mục tiêu	$\text{Outcome} \in \{0, 1\}$
Số quan sát	768 hồ sơ
Đặc trưng đầu vào	8 cột gốc, tất cả đều là số; không có biến định danh
Đặc trưng sau thiết kế	12 cột (8 gốc + 4 phái sinh)
Người dùng cuối	Bác sĩ sàng lọc, và chính người được sàng lọc
Độ đo quyết định	F_1 và Recall — không phải Accuracy

2.2 Tập dữ liệu và nguồn gốc

Tập **Pima Indians Diabetes** [14] do Viện Quốc gia về Đái tháo đường, Bệnh Tiêu hoá và Bệnh Thận Hoa Kỳ thu thập, công bố công khai trên Kaggle:

<https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database>

Toàn bộ đối tượng là nữ, từ 21 tuổi trở lên, thuộc cộng đồng người Pima — một giới hạn về phạm vi áp dụng sẽ được nêu lại ở Mục 4.5.

Bảng 2.2. Đặc tả tám đặc trưng gốc của tập Pima Indians Diabetes

Đặc trưng	Đơn vị	Trung bình	Trung vị	Ý nghĩa
Pregnancies	lần	3,845	3,0	Số lần mang thai
Glucose	mg/dL	121,656	117,0	Đường huyết sau nghiệm pháp dung nạp 2 giờ
BloodPressure	mmHg	72,387	72,0	Huyết áp tâm trương
SkinThickness	mm	29,108	29,0	Độ dày nếp gấp da cơ tam đầu
Insulin	$\mu\text{U/mL}$	140,672	125,0	Insulin huyết thanh sau 2 giờ
BMI	kg/m^2	32,455	32,3	Chỉ số khối cơ thể
DiabetesPedigreeFunction	—	0,472	0,372	Chỉ số di truyền gia đình
Age	năm	33,241	29,0	Tuổi


Nhận xét: Trung bình lớn hơn trung vị ở hầu hết các cột — dấu hiệu của phân phối lệch phải. Riêng Age chênh lệch nhiều nhất (33,2 so với 29,0), cho thấy đuôi phải kéo dài: mẫu chủ yếu là người trẻ, kèm một nhóm nhỏ tuổi cao. Các con số trong bảng được tính **sau** khi áp quy ước “0 là khuyết” ở Mục 2.3; tính trên dữ liệu thô sẽ cho trung bình Insulin thấp hơn thực tế gần một nửa.

2.3 Làm sạch dữ liệu: khi số 0 không phải là số đo

Tập dữ liệu không có ô trống nào theo nghĩa kỹ thuật — mọi ô đều có giá trị. Nhưng năm cột sinh học chứa giá trị 0, và trên một người sống thì nồng độ glucose bằng 0, huyết áp bằng 0 hay BMI bằng 0 đều là điều bất khả. Đây là **quy ước mã hoá cho “không đo được”**, không phải số đo thật.

Bảng 2.3. Số quan sát mang giá trị 0 phi lý ở năm cột sinh học

Cột	Số ca	Tỷ lệ	Vì sao 0 là bất khả
Insulin	374	48,7%	Cơ thể luôn tiết insulin nên
SkinThickness	227	29,6%	Da luôn có độ dày đo được
BloodPressure	35	4,6%	Huyết áp 0 nghĩa là ngừng tuần hoàn
BMI	11	1,4%	BMI 0 nghĩa là khối lượng cơ thể bằng 0
Glucose	5	0,7%	Glucose 0 không tương thích với sự sống



Hình 2.1. Tỷ lệ dữ liệu khuyết ở năm cột sinh học sau khi áp quy ước “giá trị 0 là dữ liệu không đo được”

Loại biểu đồ: Biểu đồ cột ngang (horizontal bar chart), sắp xếp giảm dần theo tỷ lệ khuyết. Trục ngang là tỷ lệ phần trăm, trục dọc là tên cột.

Dạng phân phối: Phân bố cực kỳ không đều giữa các cột. Hai cột đầu chiếm gần như toàn bộ lượng khuyết, năm cột còn lại gộp lại chưa tới 7%.

Chi tiết phân bố: Insulin khuyết 48,7% — gần một nửa dữ liệu. SkinThickness khuyết 29,6%. Ba cột còn lại lần lượt 4,6%, 1,4% và 0,7%. Không cột nào vượt ngưỡng loại bỏ 80% nên cả năm cột đều được giữ lại và điền khuyết bằng trung vị.

Rò rỉ nhãn qua bước điền khuyết — một sai lầm thật đã xảy ra

Bản triển khai đầu tiên điền khuyết bằng *trung vị theo nhóm Outcome* — tức người bệnh được điền bằng trung vị của người bệnh. Kết quả nhảy lên Accuracy 0,8705, vượt xa trần 0,77–0,79 mà tài liệu công bố trên cùng tập dữ liệu này [15]. Con số đẹp bất thường ấy chính là dấu hiệu của lỗi.


Nguyên nhân: với Insulin khuyết 374/768 và SkinThickness khuyết 227/768, gần một nửa dữ liệu sau khi điền đã mang dấu vết của chính nhãn cần dự đoán. Mô hình không học quan hệ sinh học; nó đọc ngược ra nhãn từ giá trị đã điền.

Cách sửa: đưa `SimpleImputer(strategy="median")` vào *bên trong* Pipeline, để fit chỉ nhìn thấy tập huấn luyện. Accuracy trở về 0,7914 — thấp hơn, nhưng là con số thật. **Bài học: một kết quả vượt trần tài liệu là lý do để đi tìm lỗi, không phải lý do để ăn mừng.**

2.4 Phân tích khám phá dữ liệu

2.4.1 Phân phối biến mục tiêu

Phân phối biến mục tiêu Outcome



Hình 2.2. Phân phối hai lớp của biến mục tiêu Outcome


Loại biểu đồ: Biểu đồ tròn (pie chart) — dạng phù hợp khi cần thể hiện tỷ trọng của một số ít hạng mục trên tổng thể.

Dạng phân phối: Lệch lớp ở mức trung bình, tỷ lệ xấp xỉ 2 : 1 nghiêng về lớp âm tính.

Chi tiết phân bố: 500 ca âm tính chiếm 65,1% và 268 ca dương tính chiếm 34,9%. Mức lệch này chưa tới ngưỡng “mất cân bằng nghiêm trọng” (thường tính từ 10 : 1) nên không cần lấy mẫu lại, nhưng đã đủ để làm Accuracy mất ý nghĩa: một mô hình đoán bừa “tất cả đều khỏe” đạt ngay 65,1%.

2.4.2 Phân phối đặc trưng quan trọng nhất

Phân phối tần suất của Glucose




Hình 2.3. Phân phối tần suất của đặc trưng Glucose

Loại biểu đồ: Biểu đồ tần suất (histogram). Dải giá trị liên tục được chia thành các khoảng bằng nhau, chiều cao mỗi cột là số quan sát rơi vào khoảng đó.

Dạng phân phối: Dạng gần chuẩn nhưng lệch phải nhẹ, một đỉnh duy nhất (unimodal).

Chi tiết phân bố: Khối lượng dữ liệu tập trung trong khoảng 90–140 mg/dL, đỉnh tại khoảng 105–115 mg/dL với gần 70 quan sát. Đuôi trái mỏng, bắt đầu từ khoảng 45 mg/dL. Đuôi phải dày hơn hẳn và kéo tới 199 mg/dL — vùng này tương ứng với ngưỡng chẩn đoán đái tháo đường (≥ 200 mg/dL sau nghiệm pháp dung nạp), nên độ dày của đuôi phải chính là tín hiệu mà mô hình khai thác.

2.4.3 So sánh phân phối giữa hai nhóm



Hình 2.4. Ước lượng mật độ hạt nhân (KDE) của Glucose, BMI và Age, tách theo tình trạng bệnh


Loại biểu đồ: Ba biểu đồ mật độ hạt nhân chồng lớp (overlaid KDE). Khác biểu đồ tần suất, KDE dùng đường cong liên tục nên hình dáng phân phối không phụ thuộc vào cách chọn độ rộng khoảng. Hai màu là hai nhóm của biến mục tiêu.

Dạng phân phối: Cả ba cặp đường cong đều lệch nhau theo cùng một hướng — nhóm mắc bệnh dịch sang phải — nhưng *mức độ* tách rời rất khác nhau.

Chi tiết phân bố: Glucose tách rõ nhất: đỉnh nhóm khoẻ ở khoảng 105 mg/dL, đỉnh nhóm bệnh ở khoảng 135–145 mg/dL, và phần chồng lấn tuy còn lớn nhưng hai đỉnh đã tách hẳn. BMI tách vừa phải, hai đỉnh chỉ cách nhau vài đơn vị quanh mốc 30–35 kg/m². Age tách yếu nhất: nhóm khoẻ có một đỉnh nhọn ở khoảng 22–25 tuổi, nhóm bệnh phân bố thoải và rộng hơn nhưng phần chồng lấn chiếm gần trọn vùng dữ liệu.

Nhận xét: Thứ tự tách rời ở đây — Glucose > BMI > Age — báo trước đúng thứ tự tương quan với nhân ở Bảng 2.5 và đúng thứ tự mức quan trọng đặc trưng ở Hình 2.15. Ba phương pháp độc lập cùng chỉ về một kết luận là bằng chứng mạnh hơn bất kỳ phương pháp nào đứng riêng.

2.4.4 Giá trị ngoại lai



Hình 2.5. Biểu đồ hộp của tám đặc trưng định lượng

Loại biểu đồ: Lưới tám biểu đồ hộp (boxplot). Hộp bao phủ khoảng tứ phân vị Q1–Q3, đường giữa là trung vị, râu kéo dài tối đa $1,5 \times IQR$, mọi điểm ngoài râu được đánh dấu là ngoại lai.

Dạng phân phối: Ba nhóm khác hẳn nhau. Nhóm gọn gàng: Glucose, BloodPressure, BMI — hộp cân đối, ít điểm ngoài râu. Nhóm lệch phải mạnh: Insulin, DiabetesPedigreeFunction, Age. Nhóm đặc biệt: SkinThickness, có hộp rất hẹp.

Chi tiết phân bố: Insulin có hộp nén sát đáy với một dải điểm ngoại lai dày đặc kéo lên tới hơn $800 \mu U/mL$ — hệ quả trực tiếp của việc 48,7% giá trị được điền bằng cùng một con số trung vị, khiến hộp co lại quanh giá trị ấy. SkinThickness cũng cho hình dáng tương tự vì lý do y hệt. Age có hộp trải từ khoảng 25 tới 41 tuổi với đuôi trên kéo tới 81. Pregnancies là biến đếm nên hình dáng bậc thang, tối đa 17 lần.

Nhận xét: Không giá trị ngoại lai nào bị loại bỏ. Với dữ liệu y sinh, một chỉ số cực đoan thường là *ca bệnh nặng* — đúng nhóm mà hệ thống sàng lọc cần phát hiện nhất. Loại bỏ chúng là loại bỏ tín hiệu, không phải loại bỏ nhiễu.

2.5 Thiết kế đặc trưng


Bốn đặc trưng phái sinh được xây từ tri thức y học, không phải từ tìm kiếm mù:

Bảng 2.4. Bốn đặc trưng thiết kế và căn cứ y học

Đặc trưng	Công thức	Căn cứ
Glucose_BMI_Risk	Glucose $\times$ BMI	Tăng đường huyết đi kèm béo phì có rủi ro cao hơn tổng rủi ro của hai yếu tố riêng lẻ — một tương tác mà mô hình tuyến tính không tự tạo ra được
Glucose_Level	Rời rạc hoá theo ngưỡng lâm sàng	Ba mức: bình thường, tiền đái tháo đường, đái tháo đường
BMI_Class	Rời rạc hoá theo phân loại WHO	Bốn mức: gầy, bình thường, thừa cân, béo phì
Age_Group	Rời rạc hoá theo nhóm tuổi	Rủi ro tăng không tuyến tính theo tuổi

2.6 Ma trận tương quan và sàng lọc đặc trưng

Ma trận tương quan Pearson (8 đặc trưng gốc + 4 đặc trưng thiết kế)



Hình 2.6. Ma trận tương quan Pearson — 8 đặc trưng gốc, 4 đặc trưng thiết kế và biến mục tiêu

Loại biểu đồ: Bản đồ nhiệt (heatmap) đối xứng. Màu đỏ là tương quan dương, màu xanh là tương quan âm, độ đậm tỷ lệ với độ lớn hệ số.

Dạng phân phối: Toàn bộ ma trận nghiêng về phía đỏ nhạt — không có cặp nào tương quan âm đáng kể. Ba cụm đậm nổi lên rõ, tất cả đều là cặp gốc – phái sinh.

Chi tiết phân bố: Ba cặp đậm nhất đều do định nghĩa mà có: Glucose–Glucose_Level = 0,87, Glucose–Glucose_BMI_Risk = 0,82, Age–Age_Group = 0,95 và BMI–BMI_Class = 0,78. Với biến mục tiêu, cột Outcome có màu nhạt hơn hẳn: hệ số cao nhất chỉ là 0,52.

Bảng 2.5. Tương quan Pearson với biến mục tiêu Outcome, sắp giảm dần

Đặc trưng	ρ	Đặc trưng	ρ
Glucose_BMI_Risk	0,5199	Age_Group	0,2322
Glucose	0,4928	Pregnancies	0,2219
Glucose_Level	0,4356	SkinThickness	0,2149
BMI	0,3120	Insulin	0,2038
BMI_Class	0,3098	DiabetesPedigreeFunction	0,1738
Age	0,2384	BloodPressure	0,1657

Nhận xét: Đặc trưng thiết kế Glucose_BMI_Risk tương quan với nhãn *mạnh hơn* cả Glucose gốc (0,5199 so với 0,4928) — bằng chứng định lượng cho thấy tri thức y học đưa vào đúng chỗ có giá trị. Ngưỡng sàng lọc $|\rho| \geq 0,20$ giữ lại năm đặc trưng gốc: Glucose, SkinThickness, Insulin, BMI, Age.

Cần nói rõ giới hạn: hệ số Pearson chỉ đo quan hệ **tuyến tính**. Giá trị gần 0 không loại trừ quan hệ phi tuyến mạnh, nên bảng này được dùng để *xếp hạng* chứ không dùng làm căn cứ duy nhất để loại đặc trưng — mọi mô hình trong chương vẫn nhận đủ 12 cột.

2.7 Chia dữ liệu và mô hình cơ sở

Áp dụng giao thức ba tập ở Mục 1.10, có phân tầng theo nhãn để giữ nguyên tỷ lệ 65/35 trong cả ba tập:

Bảng 2.6. Kích thước ba tập dữ liệu và kết quả mô hình cơ sở

Tập	Số ca	Tỷ lệ	Mô hình cơ sở	Giá trị
Huấn luyện	552	71,9%	Accuracy	0,6547
Kiểm tra	139	18,1%	Precision	0,0000
Ngoại kiểm	77	10,0%	Recall	0,0000
Tổng	768	100%	F_1	0,0000

Vì sao Accuracy 0,6547 là một con số nguy hiểm

Mô hình cơ sở luôn đoán “khỏe mạnh”. Nó đúng 65,47% số lần — nghe không tệ. Nhưng Recall bằng 0: nó **bỏ sót toàn bộ 48 người bệnh** trong tập kiểm tra. Một hệ thống sàng lọc như vậy vô dụng hoàn toàn, dù chỉ số Accuracy của nó cao hơn cả XGBoost (0,7194) ... không, thực ra thấp hơn — nhưng khoảng cách chỉ là 6 điểm phần trăm, đủ nhỏ để một báo cáo chỉ nhìn Accuracy kết luận sai rằng “mô hình học được chẳng hơn bao nhiêu”. F_1 nói đúng sự thật: 0,0000 so với 0,5895.


2.8 Thực nghiệm 1 — Đối đầu năm mô hình

Câu hỏi. Trong năm nguyên lý học khác nhau, nguyên lý nào hợp với cấu trúc của dữ liệu y sinh này?

Thiết kế. Năm mô hình nhận *cùng* một biểu diễn, *cùng* một phép chia dữ liệu, *cùng* một hạt giống ngẫu nhiên. Chỉ thuật toán thay đổi.

Bảng 2.7. Kết quả năm mô hình phân lớp trên tập kiểm tra, sắp theo F_1

Mô hình	Accuracy	Precision	Recall	F_1	ROC-AUC
Mô hình cơ sở	0,6547	0,0000	0,0000	0,0000	—
K-Nearest Neighbors	0,7842	0,6957	0,6667	0,6809	0,8462
Logistic Regression	0,7914	0,7436	0,6042	0,6667	0,8709
XGBoost	0,7194	0,5957	0,5833	0,5895	0,7905
Random Forest	0,7194	0,6154	0,5000	0,5517	0,8191
Decision Tree	0,7266	0,6786	0,3958	0,5000	0,7446



Hình 2.7. So sánh năm mô hình phân lớp trên cùng tập kiểm tra, bốn độ đo

Loại biểu đồ: Biểu đồ cột nhóm (grouped bar chart). Mỗi nhóm là một mô hình, bốn cột trong nhóm là bốn độ đo.


Nhận xét: Ba điều đáng chú ý.

(1) **Cả năm mô hình đều vượt mô hình cơ sở** ở F_1 và Recall — việc học mang lại giá trị thật, không phải chỉ là trang trí.

(2) **Hai mô hình đơn giản nhất thắng.** K-Nearest Neighbors và Logistic Regression đứng đầu, còn hai mô hình tổ hợp phức tạp hơn hẳn — Random Forest và XGBoost — lại xếp sau. Với 552 mẫu huấn luyện và 12 đặc trưng, các mô hình có phương sai cao không đủ dữ liệu để phát huy; đây là minh họa sách giáo khoa cho đánh đổi độ chệch – phương sai.

(3) **Không có mô hình nào thắng trên mọi độ đo.** Logistic Regression dẫn đầu Accuracy, Precision và ROC-AUC; K-Nearest Neighbors dẫn đầu Recall và F_1 . Với mục tiêu sàng lọc, KNN là lựa chọn đúng — nó bỏ sót ít người bệnh hơn.

2.8.1 Đường cong ROC — khả năng xếp hạng độc lập với ngưỡng



Hình 2.8. Đường cong ROC của năm mô hình phân lớp trên tập kiểm tra, kèm diện tích dưới đường cong (AUC)

Loại biểu đồ: Đường cong ROC (Receiver Operating Characteristic). Trục ngang là tỷ lệ Dương tính giả, trục dọc là Recall; mỗi điểm trên đường cong ứng với một ngưỡng quyết định. Đường chéo nét đứt là mốc đoán ngẫu nhiên.

Dạng phân phối: Cả năm đường đều nằm hẳn phía trên đường chéo — mọi mô hình đều xếp hạng tốt hơn ngẫu nhiên. Chúng bó lại thành một chùm hẹp ở góc trên bên trái rồi tỏa ra ở vùng giữa.

Chi tiết phân bố: Logistic Regression dẫn đầu với AUC = 0,8709, bám sát là K-Nearest Neighbors 0,8462 và Random Forest 0,8191. XGBoost đạt 0,7905, còn Decision Tree tụt hẳn xuống 0,7446 — đường cong của nó có dạng gãy khúc thành vài đoạn thẳng dài thay vì cong mượt.

Thứ tự trên ROC không trùng thứ tự trên F_1 — và đó không phải mâu thuẫn

Logistic Regression dẫn đầu AUC nhưng chỉ đứng thứ hai về F_1 ; K-Nearest Neighbors thì ngược lại. Hai độ đo trả lời hai câu hỏi khác nhau:


- **AUC** hỏi mô hình có xếp người bệnh lên trên người khỏe không, xét trên mọi ngưỡng cùng lúc.
- **F_1** hỏi tại ngưỡng 0,50, mô hình cắt có tốt không.

Một mô hình xếp hạng giỏi mà bị cắt sai chỗ vẫn cho F_1 thấp. Đó chính là khe hở mà Thực nghiệm 2 khai thác ở Mục 2.9: giữ nguyên mô hình, chỉ đổi điểm cắt, và F_1 tăng trong khi AUC không đổi một chút nào.

Dạng gãy khúc của đường cong Decision Tree cũng là một tín hiệu chẩn đoán: cây sâu 6 tầng chỉ trả về vài giá trị xác suất rời rạc, nên đường cong chỉ có vài điểm gấp. Chi tiết này sẽ quay lại ở Mục 2.9.

2.8.2 Lưới ma trận nhầm lẫn — sai theo kiểu gì

Ma trận nhầm lẫn của 5 mô hình — cùng thang màu



Hình 2.9. Ma trận nhầm lẫn của năm mô hình phân lớp, dùng chung một thang màu để so sánh trực tiếp

Loại biểu đồ: Lưới bản đồ nhiệt (heatmap grid), mỗi ô là một ma trận nhầm lẫn 2×2 . Mọi ô dùng chung một thang màu nên độ đậm so sánh được trực tiếp giữa các mô hình. Số FN và FP ghi ngay dưới tên mô hình.


Dạng phân phối: Cấu trúc giống nhau ở cả năm ô: ô góc trên trái (TN) luôn đậm nhất, ba ô còn lại nhạt hơn hẳn — hệ quả của việc lớp âm tính đông gần gấp đôi. Điều thay đổi giữa các mô hình là *tỷ lệ* giữa hai ô sai.

Chi tiết phân bố: K-Nearest Neighbors có FN thấp nhất (16) — nó bỏ sót ít người bệnh nhất. Decision Tree có FN cao nhất (29), gần gấp đôi, dù Accuracy của nó (0,7266) còn cao hơn XGBoost (0,7194). Ở chiều ngược lại, Decision Tree lại có FP thấp nhất (9): nó thận trọng tới mức hiếm khi báo động, và cái giá phải trả là bỏ sót.

Nhận xét: Đây là bằng chứng trực quan cho luận điểm ở Mục 1.6: **Accuracy che mắt đúng loại sai lầm đắt nhất**. Hai mô hình chênh nhau 0,7 điểm phần trăm Accuracy nhưng chênh nhau 13 người bệnh bị bỏ sót trên tổng số 48 — tức hơn một phần tư số ca cần tìm.

2.9 Thực nghiệm 2 — Siêu tham số và ngưỡng quyết định

2.9.1 Khảo sát số láng giềng k



Hình 2.10. Ảnh hưởng của số láng giềng k tới bốn độ đo của K-Nearest Neighbors

Loại biểu đồ: Biểu đồ đường đa tuyến (multi-line plot). Trục ngang là giá trị k , mỗi đường là một độ đo.

Dạng phân phối: Dạng chữ U ngược đúng như lý thuyết đánh đổi độ chệch – phương sai dự báo, với một đỉnh rõ ràng ở đầu dải và một vùng bằng phẳng kéo dài về sau.

Chi tiết phân bố: Tại $k = 1$, cả bốn độ đo đều thấp nhất ($F_1 = 0,4222$) — mô hình học thuộc từng điểm huấn luyện, phương sai cực đại. F_1 tăng vọt lên 0,6596 ở $k = 3$ rồi đạt đỉnh 0,7292 tại $k = 5$. Từ $k = 7$ trở đi đường cong đi ngang trong dải 0,6667–0,6882 mà không sụt hẳn.


Bảng 2.8. Khảo sát số láng giềng k — kết quả đầy đủ

k	Accuracy	Precision	Recall	F_1
1	0,6259	0,4524	0,3958	0,4222
3	0,7698	0,6739	0,6458	0,6596
5	0,8129	0,7292	0,7292	0,7292
7	0,7842	0,6875	0,6875	0,6875
9	0,7770	0,6667	0,7083	0,6869
11	0,7842	0,6957	0,6667	0,6809
15	0,7914	0,7209	0,6458	0,6813
21	0,7842	0,7143	0,6250	0,6667
31	0,7914	0,7111	0,6667	0,6882

Nhận xét: Giá trị $k = 11$ dùng trong danh mục mô hình ở Thực nghiệm 1 là quy tắc kinh nghiệm $k \approx \sqrt{n}$; khảo sát cho thấy $k = 5$ tốt hơn (F_1 0,7292 so với 0,6809). Chênh lệch 0,048 F_1 tương ứng khoảng 3 ca trên 139 — nằm trong biên độ nhiễu lấy mẫu của một tập kiểm tra cỡ này, nên đây là một cải thiện *có hướng* chứ chưa phải một khẳng định chắc chắn.

2.9.2 Quét ngưỡng quyết định

Đây là thực nghiệm quan trọng nhất của cả chương, vì nó thay đổi hệ thống mà *không* đụng tới mô hình.



Hình 2.11. Ảnh hưởng của ngưỡng quyết định θ tới bốn độ đo, mô hình XGBoost


Loại biểu đồ: Biểu đồ đường đa tuyến. Trục ngang là ngưỡng θ quét từ 0,60 xuống 0,05; đường nét đứt dọc đánh dấu ngưỡng tối ưu theo F_1 .

Dạng phân phối: Hai đường chính chạy ngược chiều nhau và cắt nhau — dấu hiệu kinh điển của một đánh đổi. Hai đường còn lại biến thiên nhẹ.

Chi tiết phân bố: Recall tăng đơn điệu khi θ giảm: từ 0,4583 tại $\theta = 0,60$ lên 0,9167 tại $\theta = 0,05$. Precision đi ngược lại, từ 0,5946 xuống 0,4583. Hai đường cắt nhau quanh $\theta = 0,50$. F_1 — trung bình điều hoà của hai đường ấy — đạt đỉnh 0,6508 tại $\theta = 0,15$. Accuracy gần như đi ngang trong dải 0,60–0,72 suốt cả quá trình, một lần nữa cho thấy nó không nhạy với điều đang thay đổi.

Bảng 2.9. Quét ngưỡng quyết định — bốn ô ma trận nhầm lẫn tại mỗi ngưỡng

θ	Accuracy	Precision	Recall	F_1	TP	FN	FP	TN
0,60	0,7050	0,5946	0,4583	0,5176	22	26	15	76
0,50	0,7194	0,5957	0,5833	0,5895	28	20	19	72
0,40	0,7194	0,5789	0,6875	0,6286	33	15	24	67
0,30	0,7050	0,5538	0,7500	0,6372	36	12	29	62
0,25	0,7122	0,5606	0,7708	0,6491	37	11	29	62
0,20	0,6978	0,5417	0,8125	0,6500	39	9	33	58
0,15	0,6835	0,5256	0,8542	0,6508	41	7	37	54
0,10	0,6403	0,4886	0,8958	0,6324	43	5	45	46
0,05	0,5971	0,4583	0,9167	0,6111	44	4	52	39



Hình 2.12. Ma trận nhầm lẫn của cùng một mô hình XGBoost, trước và sau khi hạ ngưỡng quyết định

Nhận xét: Đọc thẳng từ Bảng 2.9: hạ ngưỡng từ 0,50 xuống 0,15 đưa số người bệnh bị bỏ sót từ **20 xuống 7** — cứu được 13 ca trên tổng số 48. Cái giá là số báo động nhầm tăng từ 19 lên 37, tức thêm 18 người khoẻ phải đi xét nghiệm lại.

Trong bài toán sàng lọc, đây là một đổi chác rõ ràng có lợi: một lần xét nghiệm thừa tốn vài trăm nghìn đồng, còn một ca sỏi thận đường bị bỏ sót có thể dẫn tới biến chứng thận, mất hoặc tim mạch sau nhiều năm. **Điểm quan trọng nhất: mô hình không hề thay đổi** — cùng bộ trọng số, cùng ROC-AUC 0,7905. Thứ thay đổi là chỗ ta cắt.

Hai bẫy phương pháp gặp phải trong chính thực nghiệm này

Bẫy 1 — quét ngưỡng cần mô hình cho xác suất liên tục. Bản chạy đầu tiên thực hiện trên Decision Tree sâu 6 tầng. Bẫy ngưỡng từ 0,50 xuống 0,20 cho ra *đúng một* kết quả giống hệt nhau. Nguyên nhân: cây nông chỉ trả về vài giá trị xác suất rời rạc, nên phần lớn ngưỡng rơi vào cùng một khoảng và không đổi được nhân nào — đúng hiện tượng đã thấy qua dạng gãy khúc của đường ROC ở Hình 2.8. Chuyển sang XGBoost mới thấy được hiệu ứng thật, với 12 mức kết quả khác nhau trên 13 ngưỡng.

Bẫy 2 — cực trị chạm biên dải khảo sát thì chưa phải cực trị. Dải quét ban đầu dừng ở $\theta = 0,20$ và F_1 đạt đỉnh đúng tại đầu mút ấy. Chỉ sau khi nói dải xuống 0,05 mới xác nhận được đỉnh thật nằm ở 0,15. Bẫy

này lặp lại lần thứ hai ở bài toán bất động sản với độ sâu rừng ngẫu nhiên — xem Mục 3.6.


2.10 Thực nghiệm 3 — Ảnh hưởng của cách biểu diễn dữ liệu

Câu hỏi. Giữ nguyên thuật toán, chỉ đổi cách biểu diễn — kết quả thay đổi bao nhiêu, và so với biên độ do đổi thuật toán thì thế nào?

Thiết kế. Bốn phương án biểu diễn, cùng chạy trên Logistic Regression, cùng phép chia dữ liệu. Bốn phương án phản ánh đúng ba tầng chuyển hoá đã định nghĩa ở Mục 1.4.2.

Bảng 2.10. Bốn phương án biểu diễn dữ liệu và kết quả trên Logistic Regression

Phương án biểu diễn	Accuracy	Precision	Recall	F_1
Làm sạch, chưa chuẩn hoá	0,8058	0,7561	0,6458	0,6966
Thô — giữ nguyên giá trị 0 phi lý	0,7986	0,7500	0,6250	0,6818
Làm sạch + chuẩn hoá	0,7986	0,7500	0,6250	0,6818
Làm sạch + chuẩn hoá + đặc trưng thiết kế	0,7914	0,7436	0,6042	0,6667



Hình 2.13. Ảnh hưởng của cách biểu diễn dữ liệu tới F_1 của Logistic Regression

Loại biểu đồ: Biểu đồ cột ngang, sắp giảm dần theo F_1 , giá trị ghi ở đầu mỗi cột.

Dạng phân phối: Bốn cột gần bằng nhau. Khoảng cách giữa cột cao nhất và cột thấp nhất nhỏ tới mức phải đọc con số mới thấy.

Chi tiết phân bố: F_1 trải từ 0,6667 tới 0,6966 — biên độ 0,0300. Hai phương án giữa cho kết quả *trùng khít nhau tới bốn chữ số thập phân* (0,6818), tức việc chuẩn hoá không đổi được một ca nào.

Kết quả đi ngược giả thuyết ban đầu — và đây là phát hiện chính

Giả thuyết trước khi chạy là biểu diễn tốt hơn sẽ cho kết quả tốt hơn, với phương án đầy đủ nhất đứng đầu. Kết quả **ngược lại**: phương án đầy đủ nhất — có cả chuẩn hoá lẫn bốn đặc trưng thiết kế — xếp **cuối cùng**. Ba lời giải thích, mỗi lời giải thích kiểm chứng được:

1. **Chuẩn hoá không giúp gì cho Logistic Regression ở đây.** Hai phương án “có” và “không có” chuẩn hoá cho kết quả trùng khít. Điều này đúng lý thuyết: hồi quy logistic không dựa trên khoảng cách, phép chuẩn

hoá tuyến tính chỉ đổi thang trọng số chứ không đổi ranh giới quyết định. Nó *bắt buộc* với K-Nearest Neighbors, nhưng vô hại và vô ích với mô hình này.

2. **Đặc trưng thiết kế làm hại Logistic Regression.** F_1 giảm từ 0,6818 xuống 0,6667. Nguyên nhân là đa cộng tuyến dưới phạt L_2 : Glucose_BMI_Risk tương quan 0,82 với Glucose và 0,73 với BMI (Hình 2.6), nên số hạng $\lambda \|\theta\|_2^2$ ở (1.8) phân tán trọng số ra ba cột gần trùng nhau thay vì dồn vào một cột.
3. **Toàn bộ biên độ nằm trong nhiễu lấy mẫu.** 0,0300 F_1 trên 139 ca kiểm tra tương ứng chênh lệch chỉ 1–9 ca giữa các phương án. Không phương án nào tách khỏi phần còn lại một cách có ý nghĩa thống kê.

Hệ quả khái quát: “đặc trưng tốt” không phải thuộc tính của riêng đặc trưng, mà là thuộc tính của *cặp đặc trưng – thuật toán*. Chính Glucose_BMI_Risk vừa là đặc trưng tương quan mạnh nhất với nhãn (0,5199) vừa là đặc trưng quan trọng nhất của XGBoost (0,1874, xem Hình 2.15) — nhưng lại làm Logistic Regression kém đi.

2.10.1 So sánh biên độ: biểu diễn hay thuật toán?


Bảng 2.11. Biên độ do đổi biểu diễn so với biên độ do đổi thuật toán, bài toán tiểu đường

Nguồn biến thiên	Biên độ F_1	Ghi chú
Đổi cách biểu diễn (4 phương án)	0,0300	0,6667 $\rightarrow$ 0,6966
Đổi thuật toán (5 mô hình)	0,1809	0,5000 $\rightarrow$ 0,6809
Tỷ số	Thuật toán chi phối, gấp 6 lần	

Kết luận này sẽ được đối chiếu với kết quả *trái ngược* ở bài toán bất động sản tại Mục 4.2.4.

2.11 Thực nghiệm 4 — Kiểm chuẩn ngoài phân phối

Câu hỏi. Điểm số trên tập kiểm tra có lạc quan quá không?



Hình 2.14. So sánh F_1 của năm mô hình giữa tập kiểm tra và tập ngoại kiểm


Bảng 2.12. Kết quả trên tập ngoại kiểm (77 ca chưa từng dùng trong phát triển)

Mô hình	Accuracy	Precision	Recall	F_1	ROC-AUC
XGBoost	0,7922	0,6897	0,7407	0,7143	0,8800
Random Forest	0,7922	0,7037	0,7037	0,7037	0,8904
K-Nearest Neighbors	0,7922	0,7391	0,6296	0,6800	0,8904
Logistic Regression	0,7403	0,6400	0,5926	0,6154	0,8511
Decision Tree	0,7403	0,6842	0,4815	0,5652	0,7774

Nhận xét: Kết quả trên tập ngoại kiểm **cao hơn** tập kiểm tra ở hầu hết mô hình — XGBoost tăng F_1 từ 0,5895 lên 0,7143. Đây không phải bằng chứng mô hình tổng quát hoá xuất sắc; nó chủ yếu là dao động lấy mẫu trên một tập chỉ 77 ca. Điều đáng tin hơn là *thứ hạng đảo lộn*: XGBoost từ hạng ba lên hạng nhất, Logistic Regression từ hạng hai xuống hạng tư.

Hệ quả phương pháp: chênh lệch F_1 dưới khoảng 0,05 giữa hai mô hình trên tập cỡ này **không đủ để kết luận mô hình nào tốt hơn**. Đây cũng là lý do Mục 2.10 không tuyên bố phương án biểu diễn nào thắng.

2.12 Mức độ quan trọng của đặc trưng



Hình 2.15. Mức độ quan trọng của đặc trưng theo mô hình XGBoost

Loại biểu đồ: Biểu đồ cột ngang, sắp tăng dần từ trên xuống. Độ quan trọng đo bằng mức giảm độ vẩn tích lũy mà mỗi đặc trưng mang lại qua toàn bộ cây.

Dạng phân phối: Phân bố khá đều, không có đặc trưng nào áp đảo. Hai cột đầu tách khỏi phần còn lại, chín cột sau tạo thành một dải liên tục.

Chi tiết phân bố: Glucose_BMI_Risk dẫn đầu với 0,1874, kế đến Glucose gốc 0,1233. Nhóm giữa gồm Age 0,0940, Age_Group 0,0815, BMI 0,0778 và Pregnancies 0,0776. Cuối bảng là Glucose_Level với 0,0330.

Nhận xét: Ba quan sát.

(1) **Đặc trưng thiết kế đứng đầu** — bằng chứng thứ hai (sau Bảng 2.5) rằng tri thức y học đưa vào đúng chỗ có giá trị đo được, ít nhất là với mô hình cây.

(2) **Rời rạc hoá làm mất thông tin với mô hình cây.** Glucose_Level xếp cuối trong khi Glucose gốc xếp thứ hai. Điều này hợp lý: cây quyết định *tự* tìm ngưỡng chia tối ưu trên biến liên tục, nên việc rời rạc hoá thủ công thành ba mức chỉ giới hạn không gian tìm kiếm của nó. Rời rạc hoá có ích cho mô hình tuyến tính, không có ích cho cây.

(3) **Không có đặc trưng nào vượt 0,19** — tín hiệu phân tán mỏng trên nhiều biến. Điều này giải thích vì sao trần hiệu năng trên tập Pima nằm ở mức 0,77–0,79 Accuracy trong toàn bộ tài liệu công bố, và vì sao mọi kết quả vượt xa mốc ấy đều đáng nghi (xem lại khung ở Mục 2.3).

2.13 Tích hợp Đồ thị Tri thức Y sinh


2.13.1 Từ xác suất tới tầng nguy cơ

Ngưỡng phân tầng lấy trực tiếp từ Thục nghiệm 2, không phải chọn tùy ý:

Bảng 2.13. Ba tầng nguy cơ lâm sàng và ánh xạ sang mã bệnh quốc tế

Tầng nguy cơ	Ngưỡng $\hat{p}$	ICD-10	Tên mã bệnh
Nhóm Nguy cơ Cao	$\geq 0,25$	E11	Đái tháo đường Type 2
Nhóm Tiền Đái tháo đường	$\geq 0,15$	R73.0	Tăng glucose máu bất thường
Nhóm Khỏe mạnh	$\geq 0,00$	Z13.1	Khám sàng lọc đái tháo đường

2.13.2 Đồ thị của một ca cụ thể



Hình 2.16. Đồ thị Tri thức Y sinh của bệnh nhân #192 — Nhóm Nguy cơ Cao, 22 thực thể và 31 cạnh

Loại biểu đồ: Đồ thị có hướng vẽ theo bố cục phân tầng (layered graph layout). Màu nút mã hoá loại thực thể theo chú giải bên phải, nhãn trên cạnh là tên quan hệ.

Dạng phân phối: Cấu trúc hình quạt mở dần từ trái sang phải: một nút gốc duy nhất (Bệnh nhân) phân nhánh qua các tầng suy luận rồi mở rộng ra tầng hàng hoá và dịch vụ.

Chi tiết phân bố: Tầng 1 bên trái gồm bốn chỉ số sinh học cùng đặc trưng tương tác $\text{Glucose} \times \text{BMI} = 4.834$. Tầng 2 ở giữa là chuỗi Mô hình K-Nearest Neighbors $\rightarrow$ Xác suất 54,5% $\rightarrow$ ICD-10 E11 $\rightarrow$ Nhóm Nguy cơ Cao. Tầng 3 toả ra ba nhóm: hai thiết bị, ba mặt hàng dinh dưỡng, ba hướng dẫn lâm sàng. Tầng 4 gom lại thành một nút Gói Theo dõi Chuyên sâu. Tầng 5 bên phải hội tụ về nút Nhà thuốc FPT Long Châu cùng hai dịch vụ tại quầy và một đường chuyển tuyến chuyên khoa.

2.13.3 Chuỗi suy luận đầy đủ

Bảng 2.14. Chuỗi bộ ba tri thức của bệnh nhân #192, từ số đo tới nơi mua hàng

Chủ thể	Quan hệ	Đối tượng
Bệnh nhân	HAS_BIOMARKER	Glucose = 159 mg/dL
Bệnh nhân	HAS_BIOMARKER	BMI = 30,4 kg/m ²
Bệnh nhân	CALCULATED_RISK	Glucose $\times$ BMI = 4.834
Bệnh nhân	EVALUATED_BY	Mô hình K-Nearest Neighbors
Mô hình K-Nearest Neighbors	PRODUCES	Xác suất rủi ro 54,5%
Xác suất rủi ro 54,5%	MAPS_TO_DISEASE	ICD-10 E11
Bệnh nhân	STRATIFIED_AS	Nhóm Nguy cơ Cao
ICD-10 E11	REQUIRES_DEVICE	Máy đo đường huyết Accu-Chek Instant
ICD-10 E11	RECOMMENDS_NUTRITION	Sữa Abbott Glucerna 850g
Nhóm Nguy cơ Cao	ADVISES	Khám chuyên khoa Nội tiết
Nhóm Nguy cơ Cao	RECOMMENDS_PACKAGE	Gói Theo dõi Chuyên sâu
Gói Theo dõi Chuyên sâu	INCLUDES_PRODUCT	(5 mặt hàng)
Gói Theo dõi Chuyên sâu	FULFILLED_BY	Nhà thuốc FPT Long Châu
Nhà thuốc FPT Long Châu	PROVIDES_SERVICE	Đo đường huyết miễn phí tại quầy
ICD-10 E11	REFERS_TO	Khám Bác sĩ chuyên khoa Nội tiết

2.13.4 Gói chăm sóc sức khoẻ và giải pháp dược phẩm

Đây là điểm mà hệ thống trả lời được câu hỏi cuối cùng của người dùng: *vậy tôi phải mua gì, và hết bao nhiêu tiền.*

Bảng 2.15. Gói Theo dõi Chuyên sâu — danh mục mặt hàng cho Nhóm Nguy cơ Cao

Mã SKU	Mặt hàng	Khoảng giá	Định kỳ
LC-DEV-001	Máy đo đường huyết Accu-Chek Instant	790.000 – 1.090.000 đ	Không
LC-DEV-002	Que thử đường huyết Accu-Chek (hộp 50 que)	300.000 – 420.000 đ	Có
LC-DEV-003	Kim chọc máu Accu-Chek Softclix (hộp 25)	90.000 – 150.000 đ	Có
LC-NUT-001	Sữa Abbott Glucerna 850g	690.000 – 890.000 đ	Có
LC-NUT-003	Viên uống Dây thìa canh Diabetna (hộp 40)	120.000 – 195.000 đ	Có
Chi phí ban đầu		1.990.000 – 2.745.000 đ	
Duy trì hằng tháng		1.200.000 – 1.655.000 đ	
Tổng 12 tháng đầu		15.190.000 – 20.950.000 đ	

Bảng 2.16. Ba gói chăm sóc theo tầng nguy cơ

Gói	Số mặt hàng	Chi phí ban đầu	Tần suất theo dõi
Theo dõi Chuyên sâu	5	1,99 – 2,75 tr.đ	Đo đường huyết đói và sau ăn 2 giờ, mỗi ngày
Dự phòng Tiền Đái tháo đường	4	1,43 – 2,08 tr.đ	Kiểm tra lại đường huyết sau 3 tháng
Duy trì Sức khỏe	1	0,15 – 0,32 tr.đ	Khám sức khỏe định kỳ hằng năm

Nhận xét: Chi phí ban đầu và chi phí duy trì được tách riêng có chủ đích. Gói Theo dõi Chuyên sâu có máy đo là khoản mua một lần trị giá tới 1,09 triệu đồng; gộp chung hai con số sẽ khiến gói trông đắt gấp rưỡi thực tế của tháng thứ hai trở đi. Đây là loại minh bạch mà một bảng khuyến nghị chỉ liệt kê tên hàng không thể cung cấp.

Về nguồn số liệu, xin nhắc lại ranh giới đã nêu ở Mục 1.9.5: tên mặt hàng là tên thật, giá là khoảng tham khảo chốt ngày 26/08/2026, và mỗi mặt hàng mang một đường dẫn tra cứu giá hiện hành. Thuốc kê đơn — Metformin và nhóm hạ đường huyết khác — **không** nằm trong danh mục này; đồ thị chỉ ghi lời khuyến cáo “tuyệt đối không tự dùng khi chưa có chỉ định bác sĩ”.

2.14 Ứng dụng web

Trang chủ

Chẩn đoán Tiểu đường

Định giá Bất động sản

PHÂN LỚP NHỊ PHÂN - PIMA INDIANS DIABETES

Chẩn đoán nguy cơ Tiểu đường

Nhập tám chỉ số sinh học, nhận xác suất mắc bệnh cùng gói can thiệp cụ thể. Ở nào chưa đo thì cứ để trống – pipeline sẽ điền bằng trung vị học được từ tập huấn luyện, đúng như lúc huấn luyện.

Chưa có số liệu? Nạp thử một bệnh nhân có thật trong tập dữ liệu:

Nguy cơ Cao · #192

Tiến Đãi tháo đường · #444

Khoẻ mạnh · #589

Xóa form

Thông tin cá nhân

Tuổi – năm
33.00

Số lần mang thai – lần
1.00

Chỉ số khối cơ thể (BMI) – kg/m²
để trống nếu chưa đo

Kết quả xét nghiệm

Đường huyết (Glucose) – mg/dL
để trống nếu chưa đo

Huyết áp tâm trương – mmHg
để trống nếu chưa đo

Insulin huyết thanh – µU/mL
để trống nếu chưa đo

Độ dày nếp gấp da – mm
để trống nếu chưa đo

Tiền sử gia đình

Chỉ số di truyền
0.47

Mô hình dự đoán

Mô hình tốt nhất – K-Nearest Neighbors

45%

XÁC SUẤT MẮC BỆNH

Nhóm Nguy cơ Cao

MÃ BỆNH ICD-10
E11
Đái tháo đường Type 2

Cần khám chuyên khoa Nội tiết để xét nghiệm khẳng định.

Đang có 5 chỉ số bỏ trống, được điền bằng trung vị của tập huấn luyện. Đo đủ thì kết quả sát hơn.

Khuyến nghịSo sánhVị sao

Một xác suất tự nó không nói cho người dùng biết phải làm gì tiếp theo. Đồ thị tri thức bên dưới kết quả dự báo với tri thức miễn đã chuẩn hoá – mã bệnh ICD-10, thiết bị y tế, dinh dưỡng, hướng dẫn lâm sàng – và nó được dựng tại chỗ từ đúng những con số bạn vừa nhập.

Gói can thiệp — Nhóm Nguy cơ Cao

THIẾT BỊ Y TẾ

- Máy đo đường huyết Accu-Chek Instant
- Que thử đường huyết (hộp 50)

DINH DƯỠNG

- Sữa Abbott Glucerna 850g
- Viên Dây thìa canh Diabetna

HƯỚNG DẪN LÂM SÀNG

- Khám chuyên khoa Nội tiết để xét nghiệm HbA1c tĩnh mạch
- Đo đường huyết đói và sau ăn 2 giờ mỗi ngày
- Tuyệt đối không tự dùng Metformin khi chưa có chỉ định bác sĩ

ActionDeviceDiseaseModelNutritionPatientPredictionRiskTierService

SỐ THỰC THỂ (|V|)
14

SỐ CẠNH (|E|)
16

SỐ LOẠI QUAN HỆ (|R|)
9

SỐ LOẠI THỰC THỂ (|I|)
9

Bảng bộ ba tri thức – 16 bộ ba (Chủ thể, Quan hệ, Đối tượng)

Xem đồ thị gộp cả ba mẫu của miền Y tế

Đầu tiên công cụ phân loại không phải chẩn đoán y khoa. Kết quả chỉ để hỗ trợ tham khảo và không thay thế kết luận của bác sĩ.


Hình 2.17. Giao diện trang Chân đoán Tiểu đường trên máy tính — biểu mẫu nhập liệu, kết quả dự báo và đồ thị tri thức dựng tại chỗ

Loại biểu đồ: Ảnh chụp màn hình bản đã triển khai công khai, khổ máy tính 1440 px.

Chi tiết phân bố: Bố cục hai cột. Cột trái là biểu mẫu chia ba khối — thông tin cá nhân, kết quả xét nghiệm, tiền sử gia đình — với ô để trống được xử lý như dữ liệu khuyết chứ không phải giá trị 0. Cột phải hiển thị vòng tròn xác suất, nhãn tầng nguy cơ, mã ICD-10 và cảnh báo chuyển tuyến. Phía dưới là bốn tab: Khuyến nghị, Gói chăm sóc, So sánh, Vì sao.

Nhận xét: Ứng dụng nạp lại đúng các tệp `models/*.joblib` do `run_pipeline.py` sinh ra, nên biểu diễn lúc dự đoán trùng khớp biểu diễn lúc huấn luyện — toàn bộ bước điền khuyết, thiết kế đặc trưng và chuẩn hoá đều nằm bên trong Pipeline được lưu.

Chi tiết đáng chú ý về mặt thiết kế: khi người dùng để trống một ô, ứng dụng hiển thị dòng cảnh báo cho biết có bao nhiêu chỉ số đang được điền bằng trung vị của tập huấn luyện. Điều này giữ cho người dùng biết mức độ tin cậy của con số họ vừa nhận — một dự báo dựa trên 8 chỉ số đo đủ khác hẳn một dự báo mà 5 trong 8 chỉ số là giá trị điền.



Hình 2.18. Tab *Gói chăm sóc* — năm mặt hàng của Gói Theo dõi Chuyên sâu, mỗi thẻ mang mã SKU, khoảng giá và đường dẫn tra giá hiện hành

Loại biểu đồ: Ảnh chụp màn hình tab thứ hai của trang Chẩn đoán.

Chi tiết phân bố: Phần trên là biểu mẫu đã nạp sẵn hồ sơ bệnh nhân #192 — Glucose 159 mg/dL, BMI 30,4 — cùng kết quả 55% và mã ICD-10 E11. Trong tab, ba thẻ số cho chi phí ban đầu 1,99–2,75 triệu đồng, chi phí duy trì 1,20–1,66 triệu đồng mỗi tháng, và tần suất theo dõi. Bên dưới là lưới năm thẻ mặt hàng, mỗi thẻ ghi mã SKU, nhóm hàng, khoảng giá theo đơn vị bán, công dụng, nhãn “mua một lần” hoặc “mua định kỳ”, và một liên kết tra giá. Cuộn tiếp xuống dưới khung hình còn có bảng tóm tắt nhà thuốc — với con số chi phí 12 tháng đầu 15,19–20,95 triệu đồng — và khung cảnh báo nguồn giá.

Nhận xét: Khung cảnh báo ở cuối tab là phần không được lược bỏ: nó nêu rõ ngày chốt giá, nói rằng đây là gợi ý mua sắm chứ **không phải đơn thuốc**, và nhắc rằng thuốc kê đơn không nằm trong danh mục. Một giao diện bán hàng bỏ dòng này đi sẽ biến một công cụ sàng lọc thành một quảng cáo dược phẩm.

Trang chủ

Chẩn đoán
Tiểu đường

Định giá Bất
động sản

PHÂN LỚP NHỊ PHÂN - PIMA INDIANS DIABETES

Chẩn đoán nguy cơ Tiểu đường

Nhập tám chỉ số sinh học, nhận xác suất mắc bệnh cùng gói can thiệp cụ thể. Ô nào chưa đo thì cứ để trống – pipeline sẽ điền bằng trung vị học được từ tập huấn luyện, đúng như lúc huấn luyện.

Chưa có số liệu? Nạp thử một bệnh nhân có thật trong tập dữ liệu:

Nguy cơ Cao · #192

Tiền Đái tháo đường · #444

Khoẻ mạnh · #589

Xóa form

Thông tin cá nhân

Tuổi – năm

33.00

-

+

Số lần mang thai – lần

1.00

-

+

Chỉ số khối cơ thể (BMI) – kg/m²

để trống nếu chưa đo

-

+

Kết quả xét nghiệm

Đường huyết (Glucose) – mg/dL

để trống nếu chưa đo

-

+

Huyết áp tâm trương – mmHg

để trống nếu chưa đo

-

+

Insulin huyết thanh – μU/mL

để trống nếu chưa đo

-

+

Độ dày nếp gấp da – mm

để trống nếu chưa đo

-

+

Tiền sử gia đình

Chỉ số di truyền

0.47

-

+

Mô hình dự đoán

?

Hình 2.19. Giao diện trang Chẩn đoán trên điện thoại, khổ 390 px — biểu mẫu xếp dọc, thanh điều hướng tự xuống dòng

Chương 3

Hệ thống Định giá Bất động sản Việt Nam

3.1 Phát biểu bài toán

3.1.1 Hiện tượng thực tế và người dùng

Thị trường nhà đất Việt Nam thiếu một mức giá tham chiếu công khai. Người mua dựa vào giá rao của người bán, người bán dựa vào giá rao của hàng xóm, và cả hai bên đều không có cách kiểm chứng độc lập. Hệ quả là khoảng chênh lệch thương lượng rất rộng, và bên nào ít thông tin hơn thì chịu thiệt.

Một hệ thống định giá tự động không thay thế được thẩm định giá chính thức — việc ấy đòi hỏi khảo sát hiện trạng — nhưng nó cung cấp được **mốc tham chiếu độc lập** dựa trên 30.229 giao dịch thật, cùng với điều mà một con số giá đơn lẻ không nói được: vay được bao nhiêu, trả góp thế nào, và quanh đó có gì.

3.1.2 Phát biểu hình thức

Cho một hồ sơ bất động sản $\mathbf{x}$ gồm thuộc tính vật lý, vị trí hành chính và tình trạng pháp lý, hãy học hàm

$$f_{\theta} : \mathcal{X} \longrightarrow \mathbb{R}_+, \quad \hat{y} = f_{\theta}(\mathbf{x}) \approx \text{Price (tỷ VNĐ)}, \quad (3.1)$$

sao cho cực tiểu hoá sai số bình phương trung bình (1.7) trên tập huấn luyện. Khác bài toán ở Chương 2, đầu ra ở đây là số thực liên tục nên không có ngưỡng quyết định nào cần chọn — nhưng bù lại xuất hiện một vấn đề mà bài phân lớp không có: **độ chệch có hệ thống theo vùng giá trị** (Mục 3.5.2).

Bảng 3.1. Đặc tả bài toán định giá bất động sản

Hạng mục	Nội dung
Hiện tượng thực tế	Biến động giá bất động sản theo cấu trúc vật lý và vị trí
Một quan sát	Một tin đăng rao bán nhà đất
Loại bài toán	Hồi quy (Regression)
Biến mục tiêu	Price, số thực liên tục, đơn vị tỷ VNĐ
Số quan sát	30.229 tin đăng
Đặc trưng đầu vào	14 cột — 9 định lượng và 5 định danh
Số chiều sau mã hoá	84 chiều
Người dùng cuối	Người mua, người bán, nhà đầu tư, chuyên viên tín dụng
Độ đo quyết định	MAE (đọc thẳng ra tiền) và R^2 (so với đoán trung bình)

3.2 Tập dữ liệu và quy trình làm sạch

3.2.1 Nguồn dữ liệu


Tập **Vietnam Housing Dataset** [16] thu thập từ các trang rao bán bất động sản Việt Nam, công bố công khai trên Kaggle:

<https://www.kaggle.com/datasets/huutri148/vietnam-housing-dataset>

Tập nguồn có BOM ở đầu

Tập CSV bắt đầu bằng dấu Byte Order Mark. Đọc bằng `encoding="utf-8"` thông thường khiến tên cột đầu tiên mang thêm ký tự vô hình `\ufeff`, và mọi phép truy cập cột theo tên sau đó đều thất bại — nhưng thất bại theo kiểu “không tìm thấy cột” chứ không phải “tập rỗng”, nên rất dễ đi tìm sai chỗ. Phải đọc bằng `encoding="utf-8-sig"`.

3.2.2 Tỷ lệ dữ liệu khuyết



Hình 3.1. Tỷ lệ dữ liệu khuyết theo từng thuộc tính của tập bất động sản

Loại biểu đồ: Biểu đồ cột ngang, sắp giảm dần theo tỷ lệ khuyết.

Dạng phân phối: Trái rất rộng và liên tục — từ 82,6% xuống 11,9%, không có khoảng đứt gãy rõ rệt giữa nhóm “khuyết nhiều” và nhóm “khuyết ít”.

Chi tiết phân bố: Balcony direction đứng đầu với 82,6% — vượt ngưỡng loại bỏ 80% nên cột này bị loại khỏi mô hình. House direction khuyết 70,3% nhưng vẫn dưới ngưỡng nên được giữ. Tiếp theo là Furniture state 46,7%, Access Road 44,0%, Frontage 38,3%, Bathrooms 23,4%, Bedrooms 17,1%, Legal status 14,9% và Floors 11,9%. Ba cột Address, Area và Price đầy đủ hoàn toàn.


Nhận xét: Việc giữ lại House direction dù khuyết 70,3% là một quyết định có căn cứ: hướng nhà mang ý nghĩa phong thủy đáng kể trong định giá tại Việt Nam, và với biến định danh thì bản thân trạng thái “không rõ” cũng là một hạng mục có ý nghĩa — tin đăng không khai hướng nhà có thể chính là tin đăng mà hướng nhà không phải điểm mạnh.

3.2.3 Tách địa chỉ thành hai cấp hành chính

Cột Address là chuỗi tự do. Bước làm sạch tách nó thành Province và District. Dữ liệu thật để lại nhiều dạng viết khác nhau của cùng một địa danh — “Hà Nội”, “HN”, “Quận Nam Từ Liêm” xuất hiện ở cấp tỉnh; “Hồ Chí Minh giá 2tỷ380” cho thấy người đăng tin gõ lẫn giá vào ô địa chỉ. Hệ thống giữ nguyên các biến thể này thay vì hợp nhất thủ công, và xử lý bằng cơ chế gộp hạng mục hiếm ở bước mã hoá (Mục 3.4).

3.3 Phân tích khám phá dữ liệu

3.3.1 Ba biến người mua thật sự cân nhắc



Hình 3.2. Khám phá liên hợp Giá — Diện tích — Số phòng ngủ: ba phân phối biên ở hàng trên, ba quan hệ chéo ở hàng dưới

Loại biểu đồ: Lưới sáu bảng. Hàng trên là ba phân phối biên — hai biểu đồ tần suất kèm đường mật độ và một biểu đồ cột cho biến đếm. Hàng dưới là ba quan hệ — biểu đồ phân tán, biểu đồ hộp theo nhóm, và phân phối của một biến dẫn xuất.

Dạng phân phối: Ba biến ở ba chế độ phân phối hoàn toàn khác nhau. Price gần đối xứng, Area lệch phải rất mạnh, Bedrooms là biến đếm có một đỉnh trội hẳn.

Chi tiết phân bố: Price có độ lệch $-0,029$ — gần như đối xứng hoàn hảo — với trung vị 5,90 tỷ. Area có độ lệch 3,889, khối lượng dữ liệu dồn trong khoảng 30–100 m^2 với trung vị 56 m^2 , đuôi phải kéo tới 595 m^2 . Bedrooms có đỉnh áp đảo tại 3 phòng (13.703 tin, 45,3%), kể đến 4 phòng (7.740) và 2 phòng (4.290).

Hàng dưới cho ba con số quan trọng: Giá theo Diện tích có $r = 0,098$; Giá theo Số phòng ngủ có $r = 0,333$ với các hộp chồng lấn rất nhiều; và đơn giá mỗi mét vuông có độ lệch 2,135 với trung vị 102,3 triệu đồng/ m^2 .

Ba điều đi ngược trực giác, đọc được từ một hình


(1) Không được biến đổi log cho Price ở tập này. Phép biến đổi log là thao tác mặc định khi làm việc với giá nhà, vì giá nhà thị trường lệch phải mạnh. Nhưng Price ở đây gần đối xứng ($-0,029$), nên lấy log sẽ *tạo ra* độ lệch trái thay vì sửa chữa gì. Giá định phải được đo trước khi viện dẫn — xem thêm Mục 3.3.2.

(2) Diện tích gần như không định giá được căn nhà. Hệ số 0,098 có nghĩa Diện tích một mình giải thích chưa tới 1% phương sai của giá. Điều này nghe vô lý cho tới khi nhớ rằng dữ liệu trải khắp cả nước: 56 m^2 ở Cầu Giấy và 56 m^2 ở Phố Yên là hai mức giá hoàn toàn khác nhau. Diện tích chỉ có ý nghĩa *sau khi đã cố định vị trí*.

(3) Đơn giá mỗi m^2 mới là biến giữ đúng hình dáng mà trực giác mong đợi — lệch phải mạnh với độ lệch 2,135. Đây chính là biến bị *ẩn* đi khi chỉ nhìn Giá và Diện tích một cách tách rời, và là lời giải thích trực

quan cho việc vì sao District chi phối mô hình tới vậy (Mục 3.9).

3.3.2 Phân phối biến mục tiêu



Hình 3.3. Phân phối tần suất của biến mục tiêu Price

Loại biểu đồ: Biểu đồ tần suất, 30 khoảng.

Dạng phân phối: Gần đối xứng, một đỉnh rộng và bằng phẳng ở giữa, hai đuôi cắt cụt đột ngột ở cả hai đầu.

Chi tiết phân bố: Dữ liệu nằm gọn trong dải 1,0 – 11,5 tỷ VNĐ, không có một quan sát nào ngoài dải ấy. Đỉnh trải rộng trong khoảng 4–6 tỷ với chiều cao 1.700–1.870 tần mỗi khoảng. Hai đầu dừng đột ngột chứ không thoái dần — dấu hiệu đặc trưng của dữ liệu đã bị cắt biên.

Price đã bị cắt biên từ nguồn — và hệ quả không nhỏ

Thống kê đầy đủ: nhỏ nhất 1,00, lớn nhất 11,50, trung bình 5,8721, trung vị 5,90, độ lệch chuẩn 2,2119, độ lệch (skewness) $-0,029$, độ nhọn (kurtosis) $-0,8464$. Trung bình xấp xỉ trung vị và độ lệch xấp xỉ 0 — một phân phối gần đối xứng, gần như đều ở phần giữa.


Đây **không** phải hình dáng của giá bất động sản thật, vốn lệch phải rất mạnh với một đuôi dài các bất động sản siêu cao cấp. Kết luận: người thu thập dữ liệu đã lọc bỏ hai đầu trước khi công bố.

Hai hệ quả phải nói rõ:

1. R^2 ở đây **khất khe hơn bình thường**. Mẫu số của (1.15) là phương sai của Price, và phương sai ấy đã bị thu hẹp do cắt biên. Cùng một sai số tuyệt đối sẽ cho R^2 thấp hơn so với trên một tập trải rộng.
2. **Hệ thống chỉ áp dụng được trong đúng dải 1–11,5 tỷ**. Mô hình cây *không ngoại suy* — đưa vào một biệt thự 50 tỷ, nó vẫn trả về một con số nằm trong dải đã thấy lúc huấn luyện, và con số ấy sai hoàn toàn mà không có cảnh báo nào.

Giá định “giá nhà lệch phải mạnh” nghe hiển nhiên tới mức suýt trôi qua mà không ai đo. Nó đúng với thị trường thật và *sai* với tập dữ liệu này.

3.3.3 Quan hệ giữa diện tích và giá




Hình 3.4. Biểu đồ phân tán giữa Diện tích và Giá

Loại biểu đồ: Biểu đồ phân tán (scatter plot) với độ trong suốt cao để thấy mật độ điểm ở vùng chồng chất.


Dạng phân phối: Đám mây điểm dày đặc ở góc trái, thưa dần rất nhanh về phía phải; theo trục dọc thì trải gần như đều khắp dài giá.

Chi tiết phân bố: Với diện tích dưới 130 m², giá trải gần như kín toàn bộ dải 1–11,5 tỷ — cùng một mức diện tích ứng với mọi mức giá. Từ 150 m² trở lên điểm thưa hẳn nhưng vẫn không hình thành xu hướng đi lên rõ rệt: có căn 400 m² giá 3,8 tỷ nằm cạnh căn 80 m² giá 10 tỷ. Đường giới hạn trên ở mức 10–11,5 tỷ hiện ra thành một vệt ngang — chính là biên cắt đã nêu.

3.3.4 Vị trí hành chính và tình trạng pháp lý



(a) Giá trung bình theo Tỉnh/Thành



(b) Giá trung bình theo Tình trạng pháp lý

Hình 3.5. Giá trung bình theo Tỉnh/Thành (12 tỉnh dẫn đầu) và theo Tình trạng pháp lý

Loại biểu đồ: Hai biểu đồ cột đứng, mỗi cột là giá trung bình của một hạng mục.

Dạng phân phối: Hai hình cho hai câu chuyện trái ngược. Bảng bên trái có độ dốc rõ; bảng bên phải gần như phẳng hoàn toàn.

Chi tiết phân bố: Theo tỉnh, dẫn đầu là Hưng Yên 7,895 tỷ (404 tin), rồi Quảng Ninh 6,984 (110 tin), Bắc Ninh 6,402 (167 tin), Hồ Chí Minh 6,214 (11.778 tin) và Hà Nội 6,154 (10.457 tin). Chênh lệch giữa đầu và cuối bảng là khoảng 2,3 tỷ.

Theo pháp lý, ba hạng mục gần như bằng nhau: “Không rõ” 5,9263, “Sale contract” 5,8933, “Have certificate” 5,8614 — chênh lệch chỉ 0,065 tỷ, tức 1,1%.


Trung bình biên che mất cấu trúc có điều kiện

Hai hình trên gợi ý rằng pháp lý không ảnh hưởng tới giá, và rằng Hưng Yên là tỉnh đắt nhất Việt Nam. Cả hai kết luận đều sai, và sai vì cùng một lý do: *trung bình biên trộn lẫn mọi điều kiện khác*.

Hưng Yên đứng đầu không phải vì đất Hưng Yên đắt hơn đất Quận 1, mà vì 404 tin đăng ở đó tỉnh cờ là các dự án lớn; trong khi trung bình của Hồ Chí Minh bị kéo xuống bởi hàng nghìn căn nhỏ ở vùng ven. Tương tự, giấy tờ đầy đủ có giá trị thật, nhưng những căn thiếu giấy tờ trong tập này lại tập trung ở phân khúc cao hơn, và hai hiệu ứng triệt tiêu nhau khi lấy trung bình.

Mô hình cây *không* bị đánh lừa như vậy vì nó học quan hệ *có điều kiện*: sau khi đã chia theo quận, nó mới xét tới pháp lý. Bằng chứng là Legal status vẫn nhận mức quan trọng 0,0133 ở Mục 3.9 — nhỏ, nhưng khác 0 rõ rệt.

3.3.5 Ma trận tương quan



Hình 3.6. Ma trận tương quan Pearson của các đặc trưng bất động sản

Loại biểu đồ: Bản đồ nhiệt đối xứng, thang màu hai chiều từ xanh (âm) qua trắng (không tương quan) tới đỏ (dương).

Dạng phân phối: Khác hẳn ma trận ở Hình 2.6: ở đây có cả tương quan âm rõ rệt, và cột Price thì nhạt màu gần như toàn bộ.

Chi tiết phân bố: Cặp mạnh nhất là Area–Total_Area = 0,78 (đúng theo định nghĩa) và Bedrooms–Bathrooms = 0,74. Có ba tương quan âm đáng kể: Area–Room_Density = –0,59, Area–Floors = –0,32 và Area–Frontage_Ratio = –0,26. Với Price, hệ số cao nhất chỉ là 0,364 (Bathrooms), rồi 0,333 (Bedrooms), 0,309 (Floors), 0,290 (Total_Area) và 0,098 (Area).

Trần của mô hình tuyến tính đọc được ngay từ ma trận tương quan

Không đặc trưng định lượng nào tương quan tuyến tính với giá quá 0,364. Với một mô hình tuyến tính, R^2 tối đa đạt được bị chặn bởi chính các hệ số này — và Linear Regression thực tế đạt $R^2 = 0,3557$ (Bảng 3.4), gần khít với dự đoán.

Đây là một kiểm chứng đẹp: ma trận tương quan tính được *trước khi* huấn luyện bất kỳ mô hình nào đã báo trước đúng trần hiệu năng của cả một họ thuật toán. Nó cũng nói luôn rằng muốn vượt trần ấy thì phải đưa vào thông tin mà các cột định lượng không chứa — tức là các biến định danh về vị trí, đúng như Thực nghiệm 3

sẽ đo được ở Mục 3.7.

Quan hệ âm $\text{Area} - \text{Floors} = -0,32$ cũng nói một điều thật về đô thị Việt Nam: nhà mặt đất diện tích nhỏ thì xây cao lên, còn nhà diện tích lớn thường là nhà vườn hoặc biệt thự thấp tầng.

3.4 Thiết kế đặc trưng và biểu diễn

Bảng 3.2. Ba đặc trưng thiết kế cho bài toán bất động sản

Đặc trưng	Công thức	Căn cứ
Total_Area	$\text{Area} \times \max(\text{Floors}, 1)$	Tổng diện tích sàn sử dụng, thứ người mua thật sự trả tiền
Room_Density	$\frac{\text{Bedrooms} + \text{Bathrooms}}{\max(\text{Area}, 1)}$	Mật độ phòng — phân biệt nhà ở gia đình với nhà chia phòng cho thuê
Frontage_Ratio	$\frac{\text{Frontage}}{\max(\text{Area}, 1)}$	Tỷ lệ mặt tiền — đại lượng quyết định khả năng kinh doanh

Năm biến định danh được mã hoá one-hot với giới hạn 30 hạng mục phổ biến nhất mỗi biến; các hạng mục hiếm gộp chung vào một nhóm. Không có giới hạn này, riêng District với hàng trăm giá trị sẽ tạo ma trận thưa khổng lồ và khiến mô hình học thuộc từng quận hiếm thay vì học quy luật giá. Kết quả: biểu diễn cuối cùng có **84 chiều** từ 14 cột ban đầu.

Bảng 3.3. Kích thước ba tập dữ liệu và kết quả mô hình cơ sở


Tập	Số tin	Tỷ lệ	Mô hình cơ sở	Giá trị
Huấn luyện	21.764	72,0%	MAE	1,8587
Kiểm tra	5.442	18,0%	RMSE	2,2265
Ngoại kiểm	3.023	10,0%	R^2	-0,0008
Tổng	30.229	100%		

Nhận xét: $\text{MAE} = 1,8587$ của mô hình cơ sở đọc thẳng ra tiền: không dùng mô hình nào thì sai số trung bình khi định giá một căn nhà là gần **1,86 tỷ VNĐ**. $R^2 = -0,0008$ xấp xỉ 0 đúng như lý thuyết — đoán trung vị không giải thích được chút phương sai nào.

3.5 Thực nghiệm 1 — Đối đầu năm mô hình

Bảng 3.4. Kết quả năm mô hình hồi quy trên tập kiểm tra, sắp theo R^2

Mô hình	MAE	MSE	RMSE	R^2
Mô hình cơ sở (trung vị)	1,8587	4,9573	2,2265	-0,0008
XGBoost	1,0493	1,9115	1,3826	0,6141
Random Forest	1,0818	2,0184	1,4207	0,5925
Support Vector Regression	1,0743	2,0883	1,4451	0,5784
Decision Tree	1,2412	2,7519	1,6589	0,4444
Linear Regression	1,2677	3,1914	1,7865	0,3557




Hình 3.7. So sánh năm mô hình hồi quy trên cùng tập kiểm tra

Nhận xét: Thứ hạng ở đây **ngược hẳn** với bài toán tiêu đường. Hai mô hình tổ hợp phức tạp nhất — XGBoost và Random Forest — đứng đầu, còn mô hình tuyến tính đơn giản nhất đứng cuối. Lời giải thích nằm ở quy mô dữ liệu và cấu trúc quan hệ:

- **21.764 mẫu huấn luyện** so với 552 ở bài toán tiêu đường — gấp gần 40 lần. Mô hình phương sai cao giờ có đủ dữ liệu để phát huy.
- **Quan hệ giá là phi tuyến và có tương tác mạnh:** hiệu ứng của diện tích phụ thuộc hoàn toàn vào quận. Cây quyết định biểu diễn được tương tác này một cách tự nhiên; mô hình tuyến tính thì không, và trần của nó đã được ma trận tương quan báo trước.

Bài học phương pháp: *không có thuật toán nào tốt nhất một cách tuyệt đối*. Cùng một bộ năm thuật toán, chạy trên hai bài toán, cho hai thứ hạng gần như đảo ngược. Đây là lý do phải chạy đối đầu thay vì chọn theo danh tiếng.

3.5.1 Giá dự đoán so với giá thật



Hình 3.8. Giá dự đoán so với giá thật của mô hình XGBoost trên tập kiểm tra


Loại biểu đồ: Biểu đồ phân tán dự báo – thực tế, kèm đường chéo tham chiếu ứng với dự báo hoàn hảo.

Dạng phân phối: Đám mây điểm bám quanh đường chéo nhưng **thoải hơn** đường chéo: ở vùng giá thấp nó nằm phía trên, ở vùng giá cao nó nằm phía dưới.

Chi tiết phân bố: Trong khoảng 4–7 tỷ, đám mây bám sát đường chéo và tương đối hẹp. Từ 8 tỷ trở lên, gần như toàn bộ điểm rơi xuống dưới đường chéo — mô hình định giá hụt. Ở phía dưới 3 tỷ thì ngược lại, điểm nằm trên đường chéo. Hình dáng “chữ S nằm” này là dấu hiệu kinh điển của hồi quy về trung bình.

3.5.2 Phân tích phần dư

Phân tích phần dư của mô hình XGBoost



Hình 3.9. Phân tích phần dư của mô hình XGBoost — bốn góc nhìn về cách mô hình sai

Loại biểu đồ: Lưới bốn bảng: biểu đồ phân tán phần dư, biểu đồ tần suất phần dư, đồ thị Q–Q so với phân phối chuẩn, và biểu đồ cột độ lệch theo ngũ phân vị.

Dạng phân phối: Ba bảng đầu trông tương đối lành mạnh — phần dư tập trung quanh 0, gần đối xứng. Bảng thứ tư phá vỡ ấn tượng ấy: các cột không dao động ngẫu nhiên quanh 0 mà **giảm đơn điệu** từ dương sang âm.

Chi tiết phân bố: Bảng 1: đám mây phần dư nghiêng rõ rệt, dày ở vùng dự báo 4–7 tỷ. Bảng 2: phân phối phần dư gần đối xứng quanh 0 với hai đuôi tương đương. Bảng 3: Q–Q bám đường chuẩn ở phần giữa nhưng lệch ở hai đuôi — phần dư có đuôi dày hơn phân phối chuẩn. Bảng 4 là bảng quyết định, chi tiết ở Bảng 3.5.

Bảng 3.5. Độ lệch và MAE theo ngũ phân vị giá thật, mô hình XGBoost

Ngũ phân vị	Số tin	Giá thật TB	Giá dự báo TB	Độ lệch	MAE
Q1 — rẻ nhất	1.089	2,6849	3,7338	+1,0488	1,1575
Q2	1.114	4,5032	5,1497	+0,6465	0,9366
Q3 — giữa	1.133	5,9186	6,1605	+0,2419	0,7889
Q4	1.030	7,2372	6,8511	–0,3860	0,8375
Q5 — đắt nhất	1.076	8,9774	7,4930	–1,4844	1,5335

Độ chệch đơn điệu theo phân khúc — phát hiện phải nói với người dùng


Độ chệch không dao động ngẫu nhiên mà giảm đều từ +1,0488 xuống -1,4844 qua năm ngũ phân vị. Hai nguyên nhân cộng dồn:

1. **Hồi quy về trung bình [3].** Cực tiểu hoá MSE ở (1.7) kéo mọi dự báo về phía trung tâm phân phối, vì sai lớn bị phạt bình phương.
2. **Mô hình cây không ngoại suy.** Giá trị dự báo của một cây là trung bình các mẫu huấn luyện trong lá, nên nó không bao giờ vượt quá khoảng giá trị đã thấy.

MAE cũng không đều: 0,7889 ở nhóm giữa nhưng 1,5335 ở nhóm đắt nhất — gần gấp đôi. Con số MAE gộp 1,0493 là trung bình của hai chế độ sai rất khác nhau, và nó *che mất* điều đó.

Hệ quả bắt buộc phải hiển thị cho người dùng: với bất động sản cao cấp, con số hệ thống đưa ra là **cận dưới**, không phải ước lượng không chệch. Một hệ thống định giá im lặng về điều này sẽ khiến người bán nhà cao cấp bị thiệt một cách có hệ thống.

3.6 Thực nghiệm 2 — Khảo sát độ sâu của rừng ngẫu nhiên



Hình 3.10. Ảnh hưởng của độ sâu tối đa tới R^2 của Random Forest

Loại biểu đồ: Biểu đồ đường. Trục ngang là max_depth, trục dọc là R^2 .

Dạng phân phối: Dạng bão hoà cổ điển: tăng nhanh ở đầu dài, chậm dần, rồi đi ngang hoàn toàn — không có đoạn đi xuống, tức không thấy dấu hiệu học thuộc.

Chi tiết phân bố: R^2 tăng từ 0,3712 ở độ sâu 4 lên 0,5654 ở độ sâu 12 — phần lớn mức cải thiện nằm ở đoạn này. Từ 16 tới 20 chỉ còn tăng nhẹ (0,5862 → 0,5937), rồi đạt đỉnh 0,5954 tại độ sâu 24. Từ 28 trở đi đường cong bằng phẳng tuyệt đối: 0,5954, 0,5953, 0,5953.

Bảng 3.6. Khảo sát độ sâu tối đa — kết quả đầy đủ

max_depth	MAE	RMSE	R^2
4	1,4240	1,7648	0,3712
8	1,2275	1,5506	0,5146
12	1,1376	1,4671	0,5654
16	1,0947	1,4317	0,5862
20	1,0774	1,4186	0,5937
24	1,0716	1,4156	0,5954
28	1,0704	1,4157	0,5954
40	1,0703	1,4159	0,5953

Nhận xét: Bẫy “cực trị chạm biên” xuất hiện lần thứ hai trong dự án này. Dải khảo sát ban đầu dừng ở 24 và R^2 đạt đỉnh đúng tại đầu mút. Chỉ sau khi nói dài tới 40 mới xác nhận được rằng đó là đỉnh thật chứ không phải điểm cắt cụt.


Việc đường cong *không* đi xuống ở độ sâu lớn là nhờ min_samples_leaf=5: tham số này chặn cây mọc tới lá chỉ chứa một quan sát. Nó còn có tác dụng phụ quan trọng về kỹ thuật — để mặc định, rừng 200 cây trên 21.764 dòng chiếm 156 MB trên đĩa và vượt giới hạn 100 MB mỗi tệp của GitHub. Đặt bằng 5 thì còn 44 MB mà R^2 chỉ giảm từ 0,5976 xuống 0,5925.

3.7 Thực nghiệm 3 — Ảnh hưởng của cách biểu diễn dữ liệu

Thiết kế. Ba phương án biểu diễn, cùng chạy trên Random Forest độ sâu 16, cùng phép chia dữ liệu.

Bảng 3.7. Ba phương án biểu diễn và kết quả trên Random Forest

Phương án biểu diễn	MAE	MSE	RMSE	R^2
Định lượng + định danh, chưa thiết kế	1,0932	2,0294	1,4246	0,5903
Đầy đủ + đặc trưng thiết kế	1,0947	2,0497	1,4317	0,5862
Chỉ đặc trưng định lượng	1,4388	3,2988	1,8163	0,3340



Hình 3.11. Ảnh hưởng của cách biểu diễn dữ liệu tới R^2 của Random Forest

Loại biểu đồ: Biểu đồ cột ngang, sắp giảm dần theo R^2 .

Dạng phân phối: Hai cột đầu gần bằng nhau, cột thứ ba *ngắn hơn hẳn* — một khoảng đứt gãy rõ rệt, khác hẳn hình dáng gần đều ở Hình 2.13.

Chi tiết phân bố: Hai phương án có biến định danh cho R^2 0,5903 và 0,5862 — chênh nhau 0,0041, tức trong nhiều. Bỏ hết biến định danh làm R^2 tụt xuống 0,3340 — mất 0,2563, tức hơn 43% năng lực giải thích. MAE đồng thời xấu đi từ 1,0932 lên 1,4388 tỷ VNĐ.

Bảng 3.8. Biên độ do đổi biểu diễn so với biên độ do đổi thuật toán, bài toán bất động sản


Nguồn biến thiên	Biên độ R^2	Ghi chú
Đổi cách biểu diễn (3 phương án)	0,2563	0,3340 → 0,5903
Đổi thuật toán (5 mô hình)	0,2584	0,3557 → 0,6141
Tỷ số	Ngang bằng — nhưng đổi biểu diễn ít công hơn nhiều	

Nhận xét: Hai kết luận, một trong đó đi ngược kỳ vọng ban đầu.

(1) Vị trí hành chính là nhóm thông tin quyết định. Đây là kết luận mạnh nhất của cả chương, và nó nhất quán với ba bằng chứng độc lập: tương quan tuyến tính yếu của mọi biến định lượng (Hình 3.6), mức quan trọng đặc trưng (Mục 3.9), và thực nghiệm này.

(2) Ba đặc trưng thiết kế *không* giúp gì. R^2 giảm nhẹ từ 0,5903 xuống 0,5862 khi thêm chúng vào. Lý do giống hết trường hợp Glucose_Level ở Mục 2.12: cây quyết định *tự* tìm được các tổ hợp cần thiết, nên cung cấp sẵn $\text{Area} \times \text{Floors}$ chỉ thêm một cột tương quan 0,78 với cột đã có mà không thêm thông tin nào.

3.8 Thực nghiệm 4 — Kiểm chuẩn ngoài phân phối



Hình 3.12. So sánh R^2 của năm mô hình giữa tập kiểm tra và tập ngoại kiểm


Bảng 3.9. Kết quả trên tập ngoại kiểm (3.023 tin chưa từng dùng trong phát triển)

Mô hình	MAE	RMSE	R^2	ΔR^2 so với kiểm tra
XGBoost	1,1070	1,4651	0,5629	−0,0512
Random Forest	1,1310	1,4932	0,5460	−0,0465
Support Vector Regression	1,1302	1,5279	0,5246	−0,0538
Linear Regression	1,2935	1,6571	0,4408	+0,0851
Decision Tree	1,2736	1,7038	0,4088	−0,0356

Nhận xét: Khác hẳn bài toán tiểu đường, ở đây kết quả ngoại kiểm **ổn định và có thể tin được**: thứ hạng bốn mô hình đầu giữ nguyên hoàn toàn, và mức sụt R^2 đều đặn quanh 0,05 cho ba mô hình dẫn đầu. Sự khác biệt đến từ kích thước tập: 3.023 tin so với 77 ca — gấp gần 40 lần, nên dao động lấy mẫu nhỏ hơn nhiều.

Mức sụt 0,05 là biên độ lành mạnh: nó xác nhận điểm số trên tập kiểm tra có lạc quan chút ít (do đã dùng tập ấy để chọn mô hình) nhưng không phải học thuộc. Riêng Linear Regression *tăng* R^2 — mô hình có độ chệch cao thì ít nhạy với việc đổi tập, đúng như lý thuyết dự đoán.

3.9 Mức độ quan trọng của đặc trưng



Hình 3.13. Mức độ quan trọng của 15 đặc trưng dẫn đầu theo mô hình XGBoost

Loại biểu đồ: Biểu đồ cột ngang, 15 cột one-hot dẫn đầu.

Dạng phân phối: Phân bố phân mảnh — không cột đơn lẻ nào vượt 0,07, nhưng các cột dẫn đầu gần như đều thuộc cùng hai nhóm gốc.

Chi tiết phân bố: Dẫn đầu là Province_Bình Dương 0,069, rồi Province_Hồ Chí Minh 0,056, District_Hoài Đức 0,050, Province_Hà Nội 0,046. Đặc trưng định lượng đầu tiên xuất hiện là Bathrooms và Total_Area, cả hai quanh

0,028.

Bảng 3.10. Mức quan trọng cộng dồn theo nhóm đặc trưng gốc

Nhóm đặc trưng	Tổng	Nhóm đặc trưng	Tổng
District	0,4301	Floors	0,0122
Province	0,4235	Access Road	0,0075
Bathrooms	0,0287	Area	0,0072
Total_Area	0,0270	Bedrooms	0,0047
House direction	0,0217	Frontage_Ratio	0,0041
Legal status	0,0133	Room_Density	0,0038
Furniture state	0,0131	Frontage	0,0031

Hai biến vị trí chiếm 85% toàn bộ năng lực quyết định

Cộng dồn theo nhóm gốc cho một con số dứt khoát: District + Province = 0,8536, tức **85,4%** tổng mức quan trọng. Mười hai nhóm đặc trưng còn lại — gồm toàn bộ thuộc tính vật lý và pháp lý — chia nhau 14,6% còn lại.

Con số này giải thích trọn vẹn kết quả Thực nghiệm 3: bỏ biến định danh đi thì mất đúng phần lớn nhất của cấu trúc, và R^2 tụt từ 0,5903 xuống 0,3340.

Nó cũng khép lại nghịch lý ở Hình 3.5b: Legal status có trung bình biên gần như phẳng nhưng vẫn nhận mức quan trọng 0,0133 — gấp gần bốn lần Frontage. Mô hình cây khai thác được quan hệ *có điều kiện* mà trung bình biên không nhìn thấy.

Câu ngạn ngữ “vị trí, vị trí, vị trí” của giới bất động sản, ở tập dữ liệu này, có một con số cụ thể: 85,4%.


3.10 Tích hợp Đồ thị Tri thức Đô thị – Tài chính

3.10.1 Phân khúc thị trường

Bảng 3.11. Ba phân khúc thị trường và gói tín dụng tương ứng

Phân khúc	Ngưỡng	Gói vay	LTV	Lãi suất	Kỳ hạn
Cao cấp	$\geq 8,0$ tỷ	Bất động sản Cao cấp	70%	8,5%	25 năm
Trung cấp	$\geq 4,5$ tỷ	Mua nhà Linh hoạt	75%	7,9%	20 năm
Bình dân	$\geq 0,0$ tỷ	Nhà ở Xã hội	80%	4,8%	25 năm

3.10.2 Đồ thị của một ca cụ thể



Hình 3.14. Đồ thị Tri thức Đô thị – Tài chính của tin đăng #23933 — Phân khúc Cao cấp, 20 thực thể và 20 cạnh

Loại biểu đồ: Đồ thị có hướng vẽ theo bố cục phân tầng, màu nút mã hoá loại thực thể.

Dạng phân phối: Cấu trúc hình thoi: mở rộng ở tầng thuộc tính, thắt lại tại nút định giá và nút phân khúc, rồi mở rộng lần nữa ở tầng tài chính và hạ tầng.

Chi tiết phân bổ: Bên trái là bốn thuộc tính vật lý cùng nút pháp lý. Ở giữa là chuỗi Bất động sản → Quận Nhà Bè → Tỉnh Hồ Chí Minh và song song là Mô hình XGBoost → Giá 8,42 tỷ → Phân khúc Cao cấp. Bên phải chia hai nhánh: nhánh tài chính đi qua Gói vay → Trả góp 47,5 triệu/tháng → Thu nhập tối thiểu 118,7 triệu/tháng, và nhánh hạ tầng đi qua Cụm Hạ tầng Đô thị Cao cấp tới bốn tiện ích.

3.10.3 Gói tài chính mua nhà

Áp dụng công thức niên kim (1.18) và ngưỡng DTI (1.19) cho tin đăng #23933:

Bảng 3.12. Hồ sơ tài chính đầy đủ cho tin đăng #23933 (giá dự báo 8,42 tỷ VNĐ)

Khoản mục	Giá trị	Cách tính
Giá định giá	8,42 tỷ đ	Mô hình XGBoost
Tỷ lệ cho vay (LTV)	70%	Theo phân khúc Cao cấp
Hạn mức vay P	5,89 tỷ đ	$8,42 \times 0,70$
Vốn tự có tối thiểu	2,53 tỷ đ	$8,42 - 5,89$
Lãi suất danh nghĩa	8,5%/năm	Mặt bằng công bố
Kỳ hạn	25 năm (300 kỳ)	
Trả góp hằng tháng M	47,5 triệu đ	Công thức (1.18)
Tổng tiền lãi	8,34 tỷ đ	$Mn - P$
Thu nhập tối thiểu	118,7 triệu đ/tháng	$M/0,40$, công thức (1.19)

Tổng tiền lãi vượt cả dư nợ gốc

Với kỳ hạn 25 năm ở lãi suất 8,5%/năm, tổng tiền lãi là 8,34 tỷ trên khoản vay gốc 5,89 tỷ — tức **142% dư nợ gốc**. Người vay trả về cho ngân hàng tổng cộng 14,23 tỷ để mua một căn nhà định giá 8,42 tỷ.

Đây là con số mà bảng quảng cáo gói vay hiểm khi đặt cạnh con số trả góp hằng tháng, và hệ thống hiển thị nó tương minh. Lịch trả nợ còn cho thấy một điều nữa: năm đầu tiên trả 498 triệu tiền lãi nhưng chỉ giảm được 71 triệu dư nợ — phần lãi dồn hết về đầu kỳ, nên trả trước hạn trong vài năm đầu là lúc tiết kiệm được nhiều nhất.

Con số **thu nhập tối thiểu 118,7 triệu đồng mỗi tháng** là câu trả lời thẳng thắn nhất mà hệ thống đưa ra: nó nói cho người dùng biết căn nhà này có nằm trong tầm với của họ hay không, điều mà con số “8,42 tỷ” đơn thuần không nói được.

3.10.4 Tiện ích hạ tầng đô thị

Bảng 3.13. Cụm hạ tầng tiện ích theo phân khúc, phân loại theo bốn nhóm chức năng

Cụm	Bán kính	Tiện ích	Nhóm chức năng
Cao cấp	2,0 km	Trung tâm thương mại	Thương mại
		Trường quốc tế	Giáo dục
		Bệnh viện đa khoa	Y tế
		Tuyến đường vành đai	Giao thông
Trung cấp	1,5 km	Siêu thị	Thương mại
		Trường công lập	Giáo dục
		Trạm y tế phường	Y tế
		Tuyến xe buýt nội đô	Giao thông
Cơ bản	3,0 km	Chợ dân sinh	Thương mại
		Trường tiểu học	Giáo dục
		Phòng khám đa khoa	Y tế
		Tuyến xe buýt liên huyện	Giao thông

Nhận xét: Bốn nhóm chức năng được giữ cố định qua cả ba phân khúc, chỉ đổi mức độ. Cách tổ chức này cho phép so sánh trực tiếp: cùng nhu cầu y tế, phân khúc cao cấp có bệnh viện đa khoa trong bán kính 2 km còn phân khúc cơ bản có phòng khám khu vực trong bán kính 3 km.


Xin nhắc lại ranh giới ở Mục 1.9.5: đây là mô hình hoá theo phân khúc, **không phải** khảo sát thực địa từng quận — tập dữ liệu gốc chỉ có địa chỉ hành chính, không có toạ độ, nên không thể suy ra khoảng cách thật tới một siêu thị cụ thể.

Loại biểu đồ: Ảnh chụp màn hình bản đã triển khai công khai, khổ máy tính 1440 px.

Chi tiết phân bố: Cột trái là biểu mẫu chia ba khối — quy mô và kết cấu, vị trí hành chính, pháp lý và bàn giao — trong đó danh sách Quận/Huyện được lọc động theo Tỉnh/Thành đã chọn. Cột phải hiển thị giá dự báo cỡ lớn, thanh phân khúc, đơn giá mỗi m² và hạn mức vay. Bốn tab phía dưới: Gói vay, Hạ tầng & Tài chính, So sánh, Vì sao.

Nhận xét: Tab “Hạ tầng & Tài chính” là nơi hệ thống trả lời trọn vẹn câu hỏi của người mua: bốn thẻ số ở đầu tab cho trả góp hằng tháng, thu nhập tối thiểu, vốn tự có cần chuẩn bị và tổng tiền lãi cả kỳ hạn; bảng bên trái liệt kê điều khoản vay; bảng bên phải là lịch trả nợ theo từng năm với cột trả gốc, trả lãi và dư nợ còn lại.

Ứng dụng cũng hiển thị cảnh báo khi tin đăng thiếu giấy tờ: “chưa có sổ đỏ hoặc sổ hồng — phần lớn ngân hàng sẽ không nhận thế chấp tài sản này”, lấy trực tiếp từ quan hệ QUALIFIES_FOR trong đồ thị tri thức.



Hình 3.16. Tab *Hạ tầng & Tài chính* — bốn chỉ số tài chính, bảng điều khoản vay, lịch trả nợ theo năm và cụm tiện ích hạ tầng

Loại biểu đồ: Ảnh chụp màn hình tab thứ hai của trang Định giá.

Chi tiết phân bố: Bốn thẻ số ở đầu tab: trả góp 47,4 triệu đồng mỗi tháng, thu nhập tối thiểu 118,6 triệu đồng, vốn tự có 2,52 tỷ và tổng tiền lãi 8,34 tỷ — bằng 142% dư nợ gốc. Bảng bên trái liệt kê bảy dòng điều khoản vay; bảng bên phải là lịch trả nợ theo năm với ba cột trả gốc, trả lãi và dư nợ cuối năm. Cuối tab là bốn thẻ tiện ích, mỗi thẻ ghi nhóm chức năng và bán kính tiếp cận.

Nhận xét: Con số trên giao diện chênh nhẹ so với Bảng 3.12 (47,4 so với 47,5 triệu đồng) vì ứng dụng tính trên giá dự báo đầy đủ của mô hình, còn bảng trong báo cáo tính trên con số 8,42 tỷ đã làm tròn để hiển thị. Đây là chênh lệch làm tròn, không phải hai phép tính khác nhau.

Dòng chú thích dưới lịch trả nợ là chỗ hệ thống nói ra điều mà bảng quảng cáo gói vay thường không nói: năm đầu tiên trả 498 triệu tiền lãi nhưng chỉ giảm được 71 triệu dư nợ.

Trang chủ

Chẩn đoán
Tiểu đường

Định giá Bất
động sản

HỒI QUY · 30.229 TIN ĐĂNG BẤT ĐỘNG SẢN VIỆT NAM

Định giá Bất động sản

Khai diện tích, vị trí và pháp lý, nhận giá dự báo theo tỷ VNĐ cùng gói vay tương ứng. Ở định lượng để sẵn trung vị của tập dữ liệu – cũng đúng là con số mô hình đã thấy ở những tin đăng không khai báo trường đó.

Chưa có số liệu? Nạp thử một tin đăng có thật trong tập dữ liệu:

Cao cấp · #23933

Trung cấp · #15103

Bình dân · #181

Xoá form

Quy mô và kết cấu

Diện tích – m ²	56.00	-	+
Mặt tiền – m	4.50	-	+
Đường vào – m	6.00	-	+
Số tầng – tầng	3.00	-	+
Số phòng ngủ – phòng	3.00	-	+
Số phòng tắm – phòng	3.00	-	+

Vị trí hành chính

Tỉnh/Thành

Hà Nội

Quận/Huyện

Ba Vì

Pháp lý và bàn giao

Hướng nhà

Không rõ

Hình 3.17. Giao diện trang Định giá trên điện thoại, khổ 390 px

Chương 4

Kết luận và Hướng phát triển

4.1 Tổng kết kết quả

Hai hệ thống thông minh đã được xây dựng trọn vẹn, mỗi hệ thống đi hết chuỗi sáu tầng ở Hình 1.1: từ dữ liệu thật, qua biểu diễn véc-tơ, qua năm mô hình học máy được so sánh dưới cùng một giao thức, tới dự đoán, và cuối cùng tới một khuyến nghị hành động *có chi phí xác định*.

Bảng 4.1. Tổng kết hai hệ thống

	Hệ thống 1 — Tiểu đường	Hệ thống 2 — Bất động sản
Loại bài toán	Phân lớp nhị phân	Hồi quy
Quy mô dữ liệu	768 hồ sơ	30.229 tin đăng
Số chiều biểu diễn	12	84
Mô hình cơ sở	Accuracy 0,6547, Recall 0,0000	MAE 1,8587, $R^2 = -0,0008$
Mô hình tốt nhất	K-Nearest Neighbors, $F_1 = 0,6809$	XGBoost, $R^2 = 0,6141$
Độ đo phụ tốt nhất	ROC-AUC 0,8709 (Logistic Regression)	MAE 1,0493 tỷ VNĐ
Cải thiện so với cơ sở	$F_1: 0 \rightarrow 0,68$	MAE giảm 43,5%
Thuật toán hay biểu diễn chi phối	Thuật toán , gấp 6 lần	Ngang bằng
Đồ thị tri thức	5 tầng, gói chăm sóc có chi phí	5 tầng, gói vay có lịch trả nợ

Về hạ tầng: một lệnh python `run_pipeline.py` tái tạo toàn bộ trong khoảng 90 giây; 355 bài kiểm thử tự động chạy trong 17 giây; Đồ thị Tri thức gồm 117 thực thể, 133 cạnh và 28 loại quan hệ đã nạp thật lên máy chủ Neo4j Aura [17]; ứng dụng web [18] đã triển khai công khai và truy cập được từ internet [19].

4.2 Phân tích khoa học — bày phát hiện

Mục này đáp ứng yêu cầu R10. Điểm chung của bày phát hiện dưới đây: chúng đều *bác bỏ* một giả định mà người viết tin là đúng lúc mới bắt đầu, và mỗi phát hiện đều kèm bằng chứng định lượng tái lập được.

4.2.1 Phát hiện 1 — Kết quả vượt trần tài liệu là dấu hiệu của lỗi

Bản triển khai đầu tiên điền khuyết bằng trung vị theo nhóm Outcome và đạt Accuracy 0,8705 — vượt hẳn trần 0,77–0,79 mà mọi nghiên cứu công bố trên tập Pima đều dừng lại. Nguyên nhân là rò rỉ nhãn: với Insulin khuyết 374/768 và SkinThickness khuyết 227/768, gần một nửa dữ liệu sau khi điền đã mang dấu vết của chính nhãn cần dự đoán. Đưa SimpleImputer vào trong Pipeline đưa con số về 0,7914.

Bài học phương pháp: đối chiếu kết quả với trần đã công bố trong tài liệu là một bước kiểm tra rẻ tiền và hiệu quả bất ngờ. Một con số đẹp hơn dự kiến đáng để đi tìm lỗi, không phải để ăn mừng.

4.2.2 Phát hiện 2 — Quét ngưỡng đòi hỏi mô hình cho xác suất liên tục

Thực nghiệm quét ngưỡng chạy lần đầu trên Decision Tree sâu 6 tầng cho bảy ngưỡng từ 0,50 xuống 0,20 ra *đúng một* kết quả. Cây nông chỉ trả về vài giá trị xác suất rời rạc nên phần lớn ngưỡng rơi vào cùng một khoảng. Hiện

tượng này để lại một dấu vết nhìn thấy được: đường ROC của Decision Tree ở Hình 2.8 có dạng gãy khúc thành vài đoạn thẳng dài thay vì cong mượt như bốn mô hình còn lại. Chuyển sang XGBoost cho 12 mức kết quả khác nhau trên 13 ngưỡng.

Bài học: một thực nghiệm không cho kết quả có thể là do thực nghiệm sai thiết kế, không phải do hiệu ứng không tồn tại.

4.2.3 Phát hiện 3 — Cực trị chạm biên dài khảo sát thì chưa phải cực trị

Bây giờ xuất hiện **hai lần độc lập**: độ sâu rừng ngẫu nhiên đạt đỉnh ở 24 khi dài quét dừng ở 24, và ngưỡng quyết định đạt đỉnh ở 0,20 khi dài quét dừng ở 0,20. Cả hai lần đều phải nói dài mới xác nhận được đỉnh thật (lần lượt là 24 và 0,15).

Bài học: trước khi kết luận một siêu tham số là tối ưu, hãy kiểm tra nó không nằm ở đầu mút dài khảo sát. Kiểm tra này rẻ và tự động hoá được — hàm vẽ biểu đồ quét ngưỡng trong dự án đã được sửa để tự in cảnh báo “chạm biên dài quét” khi điều đó xảy ra.

4.2.4 Phát hiện 4 — “Biểu diễn quan trọng hơn thuật toán” là SAI nếu phát biểu trần

Đây là phát hiện trung tâm của cả báo cáo, và nó đáp ứng trực tiếp yêu cầu R13.

Cùng một thiết kế Thực nghiệm 3 — giữ nguyên thuật toán, chỉ đổi biểu diễn — chạy trên hai bài toán cho hai kết luận trái ngược:

Bảng 4.2. Biên độ do biểu diễn so với biên độ do thuật toán, hai bài toán

	Tiểu đường (F_1)	Bất động sản (R^2)
Biên độ do đổi biểu diễn	0,0300	0,2563
Biên độ do đổi thuật toán	0,1809	0,2584
Bên nào chi phối	Thuật toán (gấp 6)	Ngang bằng

Điều phân biệt hai trường hợp không nằm ở thuật toán, mà nằm ở chỗ phép biểu diễn có làm thay đổi lượng thông tin hay chỉ đổi dạng thông tin đã có.

- Ở bài toán bất động sản, phương án “chỉ đặc trưng định lượng” **bỏ đi** toàn bộ nhóm biến định danh — và Province cùng District không suy ra được từ bất kỳ cột nào khác. Đây là *thêm hoặc bớt thông tin*, nên tác động lớn: R^2 mất 0,2563.
- Ở bài toán tiểu đường, cả bốn phương án đều dùng đúng tám cột gốc ấy; chúng chỉ khác nhau ở chỗ có chuẩn hoá hay không, có nhân hai cột với nhau hay không. Đây là *đổi dạng* thông tin đã có, nên tác động nhỏ và nằm trọn trong nhiễu lấy mẫu: bốn phương án chỉ phân loại khác nhau **1–9 ca trên 139**.

Phát biểu đã được sửa lại cho đúng

Phát biểu ban đầu — “biểu diễn dữ liệu quan trọng hơn thuật toán” — không đứng vững qua kiểm chứng. Phát biểu đúng là:

*Biểu diễn dữ liệu chi phối kết quả khi và chỉ khi nó **thay đổi lượng thông tin** có trong biểu diễn. Khi nó chỉ đổi **dạng** của thông tin đã có — chuẩn hoá, rời rạc hoá, nhân hai cột — thì tác động của nó thường nhỏ hơn tác động của việc đổi thuật toán, và có thể nằm trọn trong nhiễu lấy mẫu.*

Đây là lý do phải chạy *cùng một thực nghiệm trên hai miền dữ liệu*: một miền đơn lẻ sẽ cho một kết luận nghe rất thuyết phục và không có cách nào phát hiện ra nó chỉ đúng một nửa.

4.2.5 Phát hiện 5 — “Đặc trưng tốt” là thuộc tính của cặp đặc trưng – thuật toán

Đặc trưng Glucose_BMI_Risk đồng thời là:

- đặc trưng **tương quan mạnh nhất** với nhân ($\rho = 0,5199$, vượt cả Glucose gốc 0,4928);
- đặc trưng **quan trọng nhất** của XGBoost (0,1874);
- và là đặc trưng **làm Logistic Regression kém đi** (F_1 giảm từ 0,6818 xuống 0,6667).

Nguyên nhân của điều thứ ba là đa cộng tuyến dưới phạt L_2 : đặc trưng này tương quan 0,82 với Glucose và 0,73 với BMI, nên số hạng $\lambda \|\theta\|_2^2$ ở (1.8) phân tán trọng số ra ba cột gần trùng nhau.

Hiện tượng đối xứng xảy ra ở phía kia: Glucose_Level — bản rời rạc hoá của Glucose — xếp *cuối bảng* mức quan trọng của XGBoost (0,0330), vì cây quyết định tự tìm được ngưỡng chia tối ưu và việc rời rạc hoá thủ công chỉ giới hạn không gian tìm kiếm của nó. Cùng một phép biến đổi có ích cho mô hình tuyến tính và có hại cho mô hình cây.

Bài học: không tồn tại “bộ đặc trưng tốt nhất” độc lập với thuật toán. Kỹ nghệ đặc trưng và chọn mô hình là một bài toán *chung*, không phải hai bước nối tiếp.

4.2.6 Phát hiện 6 — Giả định về phân phối phải được đo trước khi viện dẫn

Giả định “giá nhà lệch phải mạnh” nghe hiển nhiên tới mức suýt trôi qua mà không ai kiểm. Đo thật thì: Price có độ lệch $-0,029$, độ nhọn $-0,8464$, trung bình 5,8721 xấp xỉ trung vị 5,90, và toàn bộ dữ liệu nằm gọn trong dải 1,0–11,5 tỷ. Tập dữ liệu đã bị cắt biên từ nguồn.

Giả định đúng với thị trường thật và *sai* với tập dữ liệu này. Nếu tin theo nó, ta sẽ áp phép biến đổi log cho biến mục tiêu — và tạo ra độ lệch trái thay vì sửa chữa gì.

Cùng bài học ấy lặp lại ở một chỗ khác: Area thì *thật sự* lệch phải mạnh (độ lệch 3,889), và biến *dẫn xuất* đơn giá mỗi m^2 cũng vậy (độ lệch 2,135, trung vị 102,3 triệu đồng/ m^2). Hình dáng mà trực giác mong đợi có tồn tại trong dữ liệu — chỉ là ở một biến khác với biến ta tưởng.

4.2.7 Phát hiện 7 — Sai số gộp che mất hai chế độ sai khác hẳn nhau

Mô hình định giá có MAE gộp 1,0493 tỷ VNĐ. Tách theo ngũ phân vị giá thật thì con số ấy vỡ ra thành hai chế độ:

- Nhóm rẻ nhất: định giá **vượt** trung bình 1,0488 tỷ, MAE 1,1575.
- Nhóm giữa: gần như không chệch (+0,2419), MAE 0,7889.
- Nhóm đắt nhất: định giá **hụt** trung bình 1,4844 tỷ, MAE 1,5335 — gần gấp đôi nhóm giữa.

Độ chệch giảm *đơn điệu* qua năm nhóm — đây là quy luật, không phải nhiễu. Nguyên nhân là hồi quy về trung bình cộng với việc mô hình cây không ngoại suy ra ngoài khoảng giá trị đã thấy lúc huấn luyện.

Hệ quả bắt buộc với người dùng: với bất động sản cao cấp, con số hệ thống đưa ra là **cận dưới**. Một hệ thống định giá im lặng về điều này sẽ khiến người bán nhà cao cấp bị thiệt một cách có hệ thống — và điều tệ nhất là họ không có cách nào biết.

4.3 Phản chiếu về vai trò của biểu diễn dữ liệu

Yêu cầu R13 đòi hỏi một phản chiếu về biểu diễn dữ liệu. Ba tầng phản chiếu, đi từ cụ thể tới khái quát:

4.3.1 Tầng 1 — Biểu diễn quyết định thuật toán nhìn thấy gì

Cùng một hiện tượng thực tế cho những biểu diễn khác nhau, và mỗi biểu diễn mở ra hoặc đóng lại một họ thuật toán:

- Không chuẩn hoá thì K-Nearest Neighbors vô dụng, vì khoảng cách Euclid (1.2) bị cột Insulin thang trăm lần át hoàn toàn. Nhưng chuẩn hoá lại *không đổi được một ca nào* cho Logistic Regression — hai phương án “có” và “không có” cho F_1 trùng khít tới bốn chữ số thập phân.
- Không mã hoá biến định danh thì 85,4% năng lực quyết định của mô hình định giá biến mất, dù mọi cột định lượng vẫn còn nguyên.

4.3.2 Tầng 2 — Biểu diễn có thể mã hoá lẫn cả câu trả lời

Đây là mặt tối của tầng 1. Bước điển khuyết ở Phát hiện 1 là một phép biến đổi biểu diễn hoàn toàn bình thường về hình thức — nó chỉ thay giá trị khuyết bằng một con số hợp lý. Nhưng con số ấy được tính từ nhân, nên biểu diễn thu được đã chứa sẵn câu trả lời.

Điều nguy hiểm là hiện tượng này *không* biểu hiện thành lỗi. Mã chạy trơn tru, mọi bài kiểm thử xanh, và độ đo thì *đẹp hơn* bình thường. Dấu hiệu duy nhất là con số quá đẹp — và nó chỉ thành dấu hiệu nếu ta biết trần tham chiếu ở đâu.

4.3.3 Tầng 3 — Giới hạn của việc thiết kế biểu diễn

Kết quả Thực nghiệm 3 ở cả hai bài toán cho thấy: khi thông tin đã có sẵn trong dữ liệu, việc sắp xếp lại nó cho đẹp hơn mang lại rất ít. Bốn phương án biểu diễn ở bài toán tiểu đường chỉ chênh nhau 1–9 ca trên 139; ba đặc trưng thiết kế ở bài toán bất động sản làm R^2 giảm nhẹ chứ không tăng.

Cái mang lại nhiều là việc **đưa thêm thông tin mới vào**: biến định danh về vị trí là thứ không cột nào khác suy ra được, và chính nó tạo ra biên độ 0,2563 R^2 .

Kết luận cuối cùng về biểu diễn dữ liệu

Câu hỏi đúng khi thiết kế biểu diễn không phải “*biểu diễn này có tinh vi không*” mà là:

1. Nó có mang thêm thông tin mà dữ liệu gốc chưa có không? Nếu không, hãy hạ kỳ vọng về mức cải thiện.
2. Nó có vô tình mang thông tin từ nhân vào không? Nếu có, mọi độ đo sau đó đều vô giá trị.
3. Nó hợp với thuật toán nào? Chuẩn hoá bắt buộc với mô hình dựa trên khoảng cách, vô ích với mô hình tuyến tính, vô nghĩa với mô hình cây. Rồi rạc hoá có ích cho mô hình tuyến tính, có hại cho mô hình cây.

4.4 Vai trò của Đồ thị Tri thức — điều mô hình không làm được

Hai hệ thống trong báo cáo này có thể dừng lại ở tầng PREDICTION và vẫn đáp ứng đủ yêu cầu về học máy. Việc đi thêm hai tầng nữa cho phép trả lời những câu hỏi mà không độ đo nào chạm tới được:

Bảng 4.3. Câu hỏi mà mô hình trả lời được và câu hỏi cần tới đồ thị tri thức

	Mô hình trả lời	Đồ thị tri thức trả lời
Hệ thống Y sinh	Xác suất mắc bệnh 54,5%	Mã ICD-10 E11; 5 mặt hàng cụ thể; chi phí ban đầu 1,99–2,75 triệu đ; duy trì 1,20–1,66 triệu đ mỗi tháng; mua ở đâu; dịch vụ miễn phí nào đi kèm
Hệ thống Bất động sản	Giá dự báo 8,42 tỷ VNĐ	Hạn mức vay 5,89 tỷ; trả góp 47,5 triệu đ/tháng; tổng lãi 8,34 tỷ; thu nhập tối thiểu 118,7 triệu đ/tháng; bốn tiện ích trong bán kính 2 km

Nhận xét: Khác biệt về *loại* chứ không phải về *mức độ*. Con số 54,5% không thể trở thành “mua máy đo Accu-Chek giá 790 nghìn” bằng bất kỳ phép tính nào trên dữ liệu huấn luyện — tri thức ấy đến từ bên ngoài và phải được khai báo tường minh.

Một điểm thiết kế đáng nói: nút *gói* ở tầng 4 của cả hai đồ thị không phải trang trí. Nó biến một danh sách rời rạc thành một đơn vị **có chi phí tính được**, nhờ đó câu hỏi “theo lời khuyên này thì tốn bao nhiêu” có câu trả lời ngay trên đồ thị chứ không phải cộng tay ở tầng giao diện. Cùng vai trò ấy, nút *trả góp* ở đồ thị bất động sản biến một hạn mức tính thành một nghĩa vụ tài chính kéo dài 300 kỳ.

4.5 Hạn chế của hệ thống

Báo cáo liệt kê hạn chế một cách thẳng thắn, vì một hệ thống được mô tả quá tốt so với thực tế còn nguy hiểm hơn một hệ thống yếu được mô tả đúng.

4.5.1 Hạn chế về dữ liệu

1. **Phạm vi dân số của tập Pima rất hẹp.** Toàn bộ đối tượng là nữ, từ 21 tuổi trở lên, thuộc cộng đồng người Pima — nhóm có tỷ lệ mắc đái tháo đường thuộc hàng cao nhất thế giới. Áp dụng thẳng cho nam giới hoặc cho dân số Việt Nam là ngoại suy không có cơ sở.
2. **Tập bất động sản đã bị cắt biên.** Hệ thống chỉ áp dụng được trong dải 1–11,5 tỷ VNĐ. Ngoài dải ấy, mô hình cây vẫn trả về một con số nhưng con số đó vô nghĩa (Mục 3.3.2).
3. **Không có yếu tố thời gian.** Cả hai tập là ảnh chụp tĩnh. Giá bất động sản biến động theo chu kỳ thị trường, nhưng mô hình không có cách nào biết tin đăng thuộc thời điểm nào.
4. **Địa chỉ chỉ ở mức hành chính.** Không có tọa độ, nên không thể tính khoảng cách thật tới tiện ích. Đây là lý do cụm tiện ích ở Mục 3.10 là mô hình hoá theo phân khúc chứ không phải khảo sát thực địa.

4.5.2 Hạn chế về mô hình

1. **Độ chệch đơn điệu theo phân khúc giá** — Phát hiện 7. Hệ thống hiển thị cảnh báo nhưng không sửa được độ chệch này.
2. **Trần hiệu năng của tập Pima.** Accuracy dừng ở mức 0,77–0,79 trong toàn bộ tài liệu công bố, và tín hiệu phân tán mỏng trên nhiều đặc trưng (không đặc trưng nào vượt mức quan trọng 0,19). Đây là giới hạn của dữ liệu, không phải của thuật toán.
3. **Tập ngoại kiểm của bài toán tiểu đường quá nhỏ.** 77 ca không đủ để phân biệt hai mô hình chênh nhau dưới 0,05 F_1 (Mục 2.11).
4. **Không có ước lượng khoảng tin cậy.** Hệ thống trả về một con số điểm; một khoảng dự báo sẽ hữu ích hơn nhiều, đặc biệt ở phân khúc cao cấp nơi sai số lớn gấp đôi.

4.5.3 Hạn chế về tri thức miền trong đồ thị

Ba ranh giới đã nêu ở Mục 1.9.5 và được nhắc lại ở đây cho đầy đủ: giá được phẩm là khoảng tham khảo có ngày chốt chứ không phải bản ghi giá trực tiếp; cụm tiện ích là mô hình hoá theo phân khúc; điều kiện vay là minh hoạ theo mặt bằng lãi suất công bố chứ không phải chào giá của một ngân hàng cụ thể. Riêng *phép tính* trả góp, tổng lãi và thu nhập tối thiểu thì là toán học thuần tuý, kiểm chứng được bằng công thức (1.18) và (1.19).

4.6 Hướng phát triển

Bảng 4.4. Hướng phát triển, sắp theo tỷ lệ giá trị trên công sức

Hướng	Nội dung và lý do	Công sức
Khoảng dự báo thay cho số điểm	Dùng hồi quy phân vị hoặc conformal prediction để trả về khoảng $[\hat{y}_{thấp}, \hat{y}_{cao}]$. Giải quyết trực tiếp hạn chế lớn nhất hiện nay: người dùng không biết con số đáng tin tới đâu.	Thấp
Hiệu chỉnh độ chệch theo phân khúc	Học một hàm hiệu chỉnh trên phần dư theo ngũ phân vị (Bảng 3.5) để bù lại độ chệch đơn điệu.	Thấp
Bổ sung tọa độ địa lý	Mã hoá địa chỉ thành kinh độ – vĩ độ, tính khoảng cách thật tới tiện ích. Biến cụm tiện ích từ mô hình hoá thành đo đạc.	Trung bình
Diễn giải mức cá thể (SHAP)	Mức quan trọng hiện tại là mức toàn cục. SHAP cho biết <i>với căn nhà này</i> , đặc trưng nào đẩy giá lên hay xuống bao nhiêu.	Trung bình
Yếu tố thời gian	Thu thập dữ liệu có mốc thời gian để mô hình hoá chu kỳ thị trường.	Cao
Mở rộng đồ thị tri thức	Nối thêm dữ liệu quy hoạch, hạ tầng giao thông đang xây, và lịch sử giao dịch theo khu vực.	Cao

Tài liệu tham khảo

- [1] Shachar Kaufman, Saharon Rosset, Claudia Perlich **and** Ori Stitelman. “Leakage in Data Mining: Formulation, Detection, and Avoidance”. *in ACM Transactions on Knowledge Discovery from Data*: 6.4 (2012). Khung phân loại rò rỉ dữ liệu; nền tảng cho Phát hiện 1, **pages** 1–21.
- [2] Christopher M. Bishop. *Pattern Recognition and Machine Learning*. Hàm sigmoid, entropy chéo và mô hình xác suất cho bài toán phân lớp. Springer, 2006.
- [3] Trevor Hastie, Robert Tibshirani **and** Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2 **edition**. Đánh đổi độ chệch – phương sai; điều chuẩn L_2 ; hồi quy về trung bình. Springer, 2009.
- [4] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort **and others**. “Scikit-learn: Machine Learning in Python”. *in Journal of Machine Learning Research*: 12 (2011), **pages** 2825–2830.
- [5] Thomas M. Cover **and** Peter E. Hart. “Nearest Neighbor Pattern Classification”. *in IEEE Transactions on Information Theory*: 13.1 (1967), **pages** 21–27.
- [6] Leo Breiman. “Random Forests”. *in Machine Learning*: 45.1 (2001), **pages** 5–32.
- [7] Corinna Cortes **and** Vladimir Vapnik. “Support-Vector Networks”. *in Machine Learning*: 20.3 (1995), **pages** 273–297.
- [8] Tianqi Chen **and** Carlos Guestrin. “XGBoost: A Scalable Tree Boosting System”. *in Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*: 2016, **pages** 785–794.
- [9] Tom Fawcett. “An Introduction to ROC Analysis”. *in Pattern Recognition Letters*: 27.8 (2006). Cơ sở của Hình 2.7; vì sao ROC-AUC độc lập với ngưỡng quyết định, **pages** 861–874.
- [10] Aidan Hogan, Eva Blomqvist, Michael Cochez **and others**. “Knowledge Graphs”. *in ACM Computing Surveys*: 54.4 (2021). Định nghĩa hình thức $\mathcal{KG} = (V, E, R)$ dùng ở công thức (1.16), **pages** 1–37.
- [11] Shaoxiong Ji, Shirui Pan, Erik Cambria, Pekka Marttinen **and** Philip S. Yu. “A Survey on Knowledge Graphs: Representation, Acquisition and Applications”. *in IEEE Transactions on Neural Networks and Learning Systems*: 33.2 (2022), **pages** 494–514.
- [12] World Health Organization. *International Statistical Classification of Diseases and Related Health Problems, 10th Revision (ICD-10)*. Nguồn của các mã E11, R73.0 và Z13.1 dùng trong đồ thị y sinh. 2019. URL: <https://icd.who.int/browse10>.
- [13] World Health Organization. *Obesity: Preventing and Managing the Global Epidemic*. techreport. Ngưỡng phân loại BMI dùng cho đặc trưng thiết kế BMI_Class. WHO Technical Report Series 894, 2000.
- [14] National Institute of Diabetes and Digestive and Kidney Diseases. *Pima Indians Diabetes Database*. Kaggle. Tập dữ liệu của Hệ thống 1, 768 hồ sơ y sinh. 2016. URL: <https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database>.
- [15] Jack W. Smith, J. E. Everhart, W. C. Dickson, W. C. Knowler **and** R. S. Johannes. “Using the ADAP Learning Algorithm to Forecast the Onset of Diabetes Mellitus”. *in Proceedings of the Annual Symposium on Computer Application in Medical Care*: (1988). Công bố gốc của tập Pima; nguồn của mốc tham chiếu 0,77–0,79 Accuracy, **pages** 261–265.
- [16] Huu Tri Nguyen. *Vietnam Housing Dataset*. Kaggle. Tập dữ liệu của Hệ thống 2, 30.229 tin đăng bất động sản. 2024. URL: <https://www.kaggle.com/datasets/huutri148/vietnam-housing-dataset>.
- [17] Neo4j, Inc. *Neo4j Graph Database — Aura Cloud Service*. Máy chủ đồ thị dùng để nạp 117 thực thể và 133 cạnh. 2026. URL: <https://neo4j.com/docs/>.

- [18] Snowflake Inc. *Streamlit — A Faster Way to Build and Share Data Apps*. Nền tảng của ứng dụng web ở Mục 2.13 và 3.12. 2026. URL: <https://docs.streamlit.io>.
- [19] Duy Nghĩa Nguyễn. *Assignment 01 — Từ Biểu diễn Dữ liệu đến Hệ thống Thông minh Đầu tiên*. GitHub. Toàn bộ mã nguồn, notebook, bộ kiểm thử và mã LaTeX của báo cáo này. 2026. URL: <https://github.com/Nghaiz/Assignment-01-Intelligent-System>.
- [20] Aurélien Géron. *Hands-On Machine Learning with Scikit-Learn, Keras and TensorFlow*. 3 **edition**. Pipeline chống rò rỉ dữ liệu; quy trình thực nghiệm. O'Reilly Media, 2022.
- [21] Sebastian Raschka **and** Vahid Mirjalili. *Python Machine Learning*. 3 **edition**. Tài liệu trong thư mục TAILIEU của dự án. Packt Publishing, 2019.
- [22] François Chollet. *Deep Learning with Python*. 2 **edition**. Tài liệu trong thư mục TAILIEU của dự án. Manning Publications, 2021.
- [23] Takaya Saito **and** Marc Rehmsmeier. “The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets”. *in PLoS ONE*: 10.3 (2015). Cơ sở cho việc chấm điểm bằng F_1 thay vì Accuracy, e0118432.